Module 1: Introduction au Machine Learning

Igor Colin, igor.colin@gmail.com

Telecom Evolution, Paris, France

Intervenants

- **Igor Colin**
  - Contact: `igor.colin@gmail.com`
  - Profil: Enseignement/Recherche/Conseil/Industrie
  - Web: http://igorcolin.github.io/
  - Mots-clés: optimisation, apprentissage statistique, applications: vie privée, télécommunications, Internet des objets
- **Stephan Clémençon** (Telecom ParisTech - STA)
  - Contact: `stephan.clemencon@telecom-paristech.fr`
  - Profil: Enseignement/Recherche/Conseil/Industrie
  - Web: http://www.tsi.enst.fr/∼clemenco/
- **Ons Jelassi** (Telecom ParisTech - Groupe STA)
  - Contact: `ons.jelassi@telecom-paristech.fr`
  - Profil : Enseignement/Recherche/Conseil

Outline

Introduction
- Des problèmes variés
- De nombreux objectifs

Théorie de l'apprentissage statistique

L'optimisation en machine learning

Objectif de la formation

Pourquoi cette formation?

- Facile d'être data-scientist en herbe (MOOC, Stack/Math Overflow, scikit-learn, *etc.*)
- Plus compliqué de vraiment savoir quoi faire
- Encore plus difficile de savoir interpréter ce que l'on obtient, surtout quand cela ne fonctionne pas

Cette formation donne des pistes/intuitions/philosophies pour **comprendre et appliquer** les méthodes de *Machine Learning*

Motivations pour le Machine Learning

- Explosion des capacités de stockage
- Bases de données **massives**
  - ex: finance, génomique, marketing, industrie ...
- Massive signifie beaucoup de lignes (observations) mais aussi souvent beaucoup de colonnes (dimensions)
  illustration
  - ex: texte ($\sim 10^5$ dimensions), photo ($\sim 10^8$ dimensions), *etc.*
- Les données ont des formes très variées : hétérogènes, (non) structurées, données approchées, prétraitées
- Les problèmes ont des contextes et des contraintes spécifiques: interprétabilité, causalité, *feedback*
- On souhaite développer des approches génériques et **automatisables**

Les données aujourd'hui

Les chiffres du travail (1)

Peu de lignes, peu de colonnes mais **données déjà traîtées ou aggrégées**

	A	B	C	D	E	F	G	H	I
1									
2	**Taux d'activité par tranche d'âge de 1975 à 2005**								
3	**En %**								
4		**1975**	**1976**	**1977**	**1978**	**1979**	**1980**	**1981**	**1982**
5	**Femmes**								
6	15-24 ans	45,5	45,7	45,2	43,9	44,2	42,9	42,1	41,87
7	25-49 ans	58,6	60,3	62,1	62,8	64,7	65,4	66,2	67,55
8	50 ans et plus	42,9	43,1	44,4	43,9	44,8	45,9	45,2	43,47
9	Ensemble	51,5	52,5	53,6	53,6	54,8	55,1	55,1	55,29
10	**Hommes**								
11	15-24 ans	55,6	54,7	53,7	52,2	52,5	52,0	50,4	45,02
12	25-49 ans	97,0	97,1	96,9	96,9	96,9	97,1	96,9	96,75
13	50 ans et plus	79,5	78,8	79,5	78,8	79,4	78,3	75,4	71,65
14	Ensemble	82,5	82,2	82,1	81,6	81,8	81,5	80,4	78,14

Figure: Taux d'activité par tranche d'âge hommes vs. femmes (source: `www.insee.fr`).

Les chiffres du travail (2)

Peu de lignes, peu de colonnes mais **données déjà traîtées ou aggrégées**

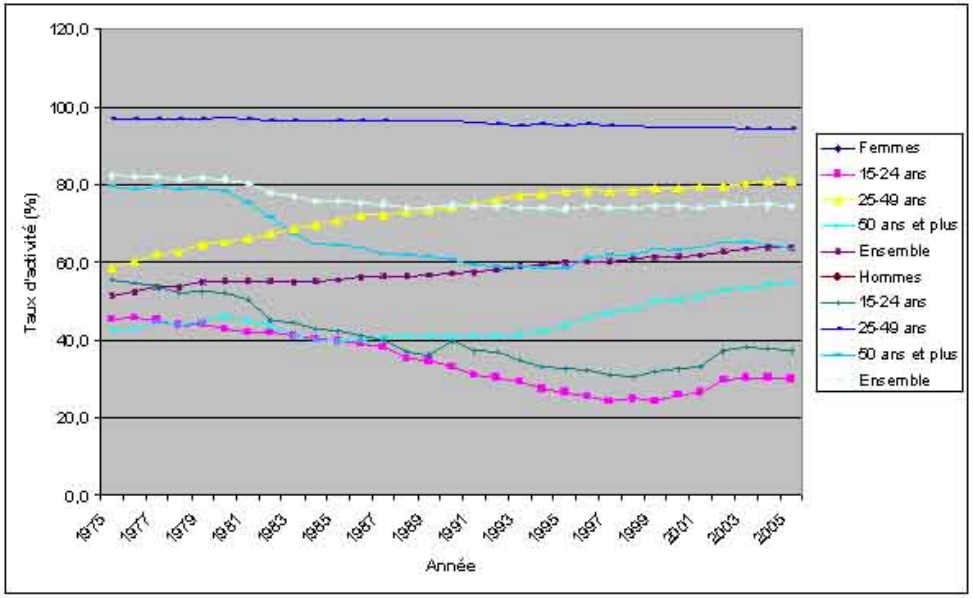

Figure: Taux d'activité par tranche d'âge hommes vs. femmes (source: `www.insee.fr`).

Le monde de la finance

Peu de dimensions mais **énormément de lignes** et **pas d'indépendance**

DOW JONES INDUSTRIAL AVERAGE IN (DJI:^DJI)

Dern. Cours:	**13.820,19**
Heure:	21 sept.
Variation:	↑ 53,49 (0,39%)
Clôture Préc.:	13.766,70
Ouverture:	13.768,33
Var. Journalière:	13.768,25 - 13.877,17
Var. sur 1 an:	11.926,80 - 14.121,00
Volume:	419.389.397

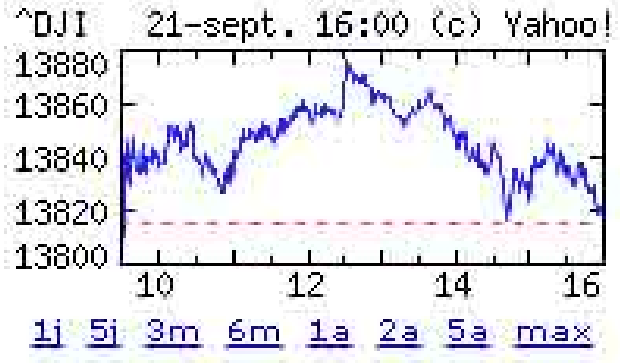

Figure: Cours du Dow Jones (source: `fr.finance.yahoo.com`).

L'imagerie médicale (1)

Peu de lignes, **énormément de colonnes**, données **structurées**, **interprétabilité**, **causalité**

L'imagerie médicale (2)

Peu de lignes, **énormément de colonnes**, données **structurées**, **interprétabilité**, **causalité**

Internet

Beaucoup de lignes et de colonnes, **données structurées**, **feedback**

Séquençage du génome humain

Nombre modéré de lignes, **énormement de colonnes**, **structure**, **redondance**

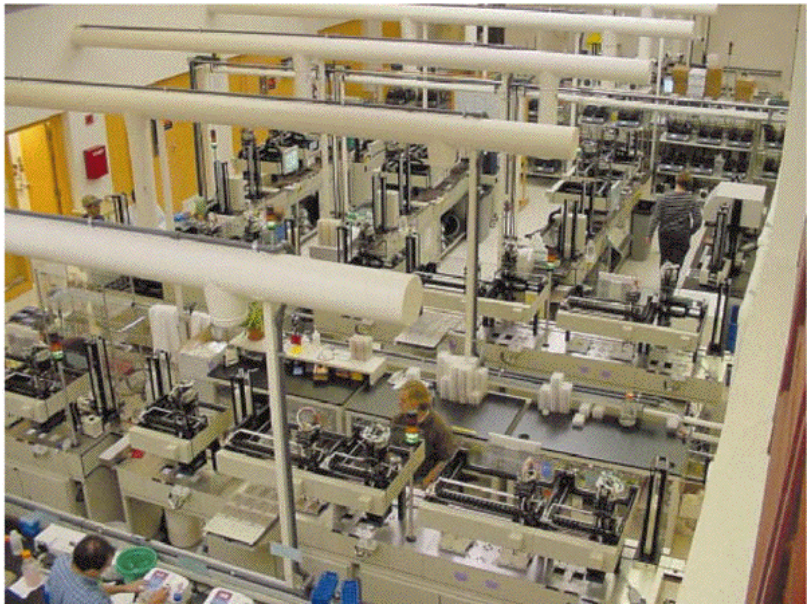

Figure: Plate-forme de séquençage génotypage OUEST-genopole

E-marketing (1)

Dimension explosive, **structure** (inconnues ?), peu de tentatives

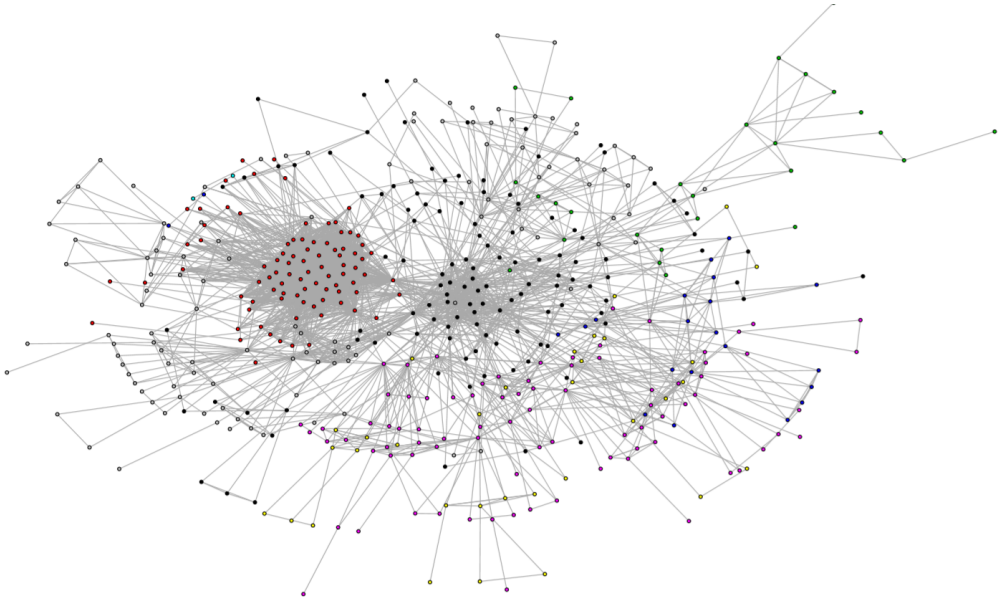

Figure: Réseau d'influences de lecteurs

E-marketing (2)

Dimension explosive, **structure** (inconnues ?), peu de tentatives

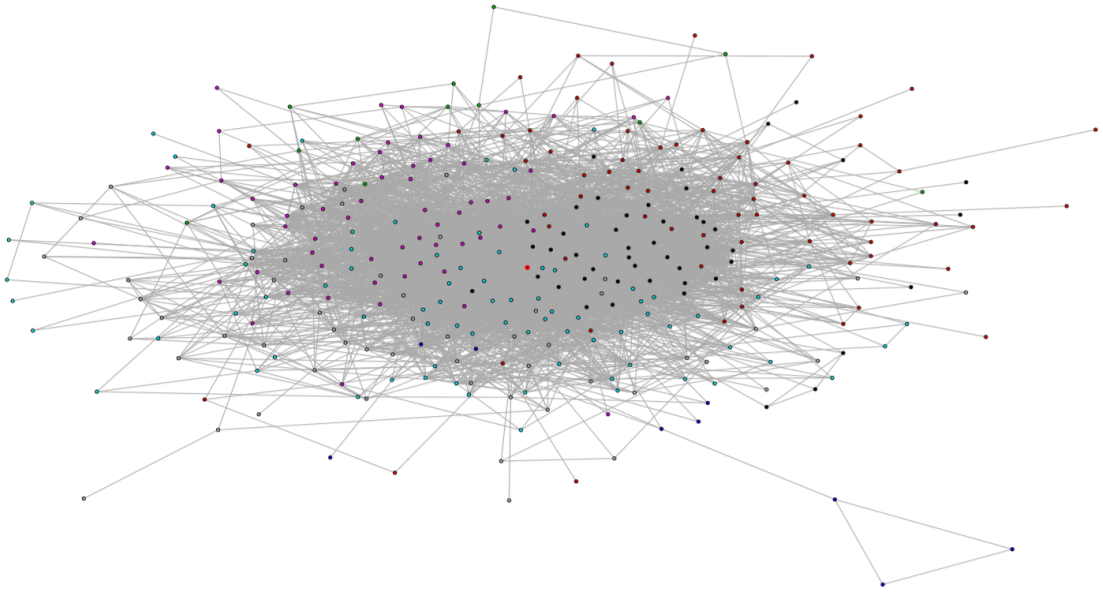

Figure: Réseau d'influences de joueurs

Nature des données

- **Vecteurs**/Matrices (*e.g.* image pixelisée)
- Chaînes de caractères (*e.g.* texte)
- **Graphes**/Réseaux
- Fonctions/**Séries temporelles** (*e.g.* vidéo, audio)

Les questions de Machine Learning

- Prédiction
- Segmentation/Clustering
- Détection d'anomalies
- Réduction de la dimension
- Sélection de variables
- Interprétation/Parcimonie
- Visualisation

Le preprocessing, une étape critique

- Nettoyage ou filtrage des données
- Données incomplètes
- Données aberrantes
- Données hétérogènes ou multi-échelles
- Indexation, "feature extraction" (*e.g.* "bag-of-words")

Un domaine pour les aborder tous

Objectifs du Machine Learning : élaborer des méthodes

- automatiques
- rapides
- précises

pour traîter

- différents types de données
- différentes tâches
- différentes contraintes

Peut-on trouver une méthode répondant à ces critères ?

Un domaine pour les aborder tous

Objectifs du Machine Learning : élaborer des méthodes

- automatiques
- rapides
- précises

pour traîter

- différents types de données
- différentes tâches
- différentes contraintes

Peut-on trouver une méthode répondant à ces critères ?

Pas si l'on veut une méthode **efficace** (*No Free Lunch*)

Domaines afférents

- Informatique :
  - BDD
  - algorithmique
- **Machine Learning :**
  - méthodes effectives pour la grande dimension/volumétrie
- **Mathématiques :**
  - algèbre linéaire
  - **modélisation aléatoire**,
  - probabilités / **statistique**
  - **optimisation**
  - traitement du signal

Machine Learning vs. Statistiques (1)

Apprentissage **statistique** : quelle différence avec les statistiques dites classiques ?
Cours de statistiques "typique" :

- Estimation paramétrique
- Intervalles/Domaines de confiance
- Tests d'hypothèses
- Régression
- Analyse en composantes principales

Machine Learning vs. Statistiques (2)

Aspects non abordés dans ce type de cours

- **Classification**
- Méthodes **non-paramétriques**
- Performances **non-asymptotiques**
- Sélection de modèle
- Théorie de la décision
- **Optimisation**, contraintes de calcul (temps quasi-réel, stockage et calcul distribués)

Pourquoi faire appel à l'apprentissage statistique?

- Typologie des problèmes
- No Free Lunch !
- Choix des critères de performance
- Notion de risque
- Contrôle de la complexité
- Validation des règles de décision
- Rôle du rééchantillonnage
- Monitoring des modèles de prévision
- Intégration des contraintes computationnelles

Documentation

- Livres:
  - The Nature of Statistical Learning Theory (2000) - Springer par V. Vapnik
  - An Introduction to Statistical Learning with Applications in R (2013) - Springer par G. James, T. Hastie, R. Tibshirani, D. Witten
  - The Elements of Statistical Learning (2001) - Springer par T. Hastie, R. Tibshirani, J. Friedman
  - Principles and Theory for Data Mining and Machine Learning (2009) - Springer par B. Clarke, E. Fokoue et H. Zhang
- Article :
  - "The curse and blessings of dimensionality" D. Donoho - IMS

Logiciels

- Librairies au niveau de l'état de l'art:
  - **Machine Learning in Python, Scikit-Learn**
    `http://scikit-learn.org/stable/`
  - **The R Project for Statistical Computing**
    `http://cran.r-project.org/web/views/MachineLearning.html`
- **Large-Scale Machine Learning**: MLlib, la librairie Machine Learning de Spark Apache
  `http://spark.apache.org/mllib/`
- Autres applications/frameworks (logiciels libres) :
  - WEKA
  - Orange
  - RapidMiner

Machine Learning: les acteurs

- Monde académique:
  - Départements: Maths (Appli), Informatique, Bioinformatique, etc.
    Un savoir fondamental selon le panorama dressé par Carnegie Mellon (création du 1er Master en ML en 2000)
  - Journaux: JMLR, Machine Learning, Data-Mining and Knowledge Discovery, etc.
  - Conférences: NIPS, ICML, COLT, UAI, etc.

- Industrie:
  - High-tech: web (google, AWS, Facebook, IBM, *etc.*), aéronautique
  - Infrastructures (*e.g.* General Electric)
  - Santé, médecine (personnalisée)
  - Finance
  - Traitement du signal, de l'image ou de la parole
  - ...

Outline

Introduction

Théorie de l'apprentissage statistique
- Une base théorique nécessaire
- Du surapprentissage
- Quelques modèles simples
- Se prévenir contre le surapprentissage

L'optimisation en machine learning

Machine Learning: les problèmes statistiques revisités

Machine Learning - Repères Historiques

- 1943: Modèle neuronal artificiel - McCullough, Pitts
- 1958: Perceptron Monocouche - Rosenblatt
- 60's: Data-mining - John Tukey
- 1971: Loi Uniforme des Grands Nombres - Vapnik, Chervonenkis
- 1974, 1986: Algorithme de rétropropagation et réseaux de Neurones
- 80's: CART (Breiman, Friedman, Stone, Olshen), SVM
- 90's: Algorithmes: Noyaux, Boosting, Forêts Aléatoires, *etc.*
- 1995: Théorie de l'Apprentissage Statistique - Vapnik
- 2000's: Web data, moteurs de recherche/recommandation, publicité en ligne, *etc.*
- 10's: Renaissance des réseaux de neurones (GPU), Deep Learning

Quelques définitions (1)

Variable aléatoire

- Résultat d'une expérience aléatoire pouvant prendre différentes valeurs avec des probabilités données (loi de la variable)
- Pile ou Face : $X = 0$ si pile, 1 si face
- Taille : $X =$ taille d'une personne tirée au hasard dans une population donnée
- Paire de variables : $(X, Z) =$ (taille, poids)

Indépendance

- Deux variables aléatoires sont indépendantes si le résultat de l'une ne donne pas d'information supplémentaires sur la réalisation de l'autre
- Pile ou Face : X et Z basées sur 2 tirages consécutifs sont indépendantes
- Physiologie : $(X, Z) =$ (taille, poids) ne sont pas indépendantes

Quelques définitions (2)

Espérance

- L'espérance d'une variable aléatoire est la moyenne de ses valeurs pondérées par leurs probabilités de réalisation
- Pile ou Face : $\mathbb{E}[X] = (1/2) \times 0 + (1/2) \times 1 = 1/2$
- Taille :

$$\mathbb{E}[X] = \sum_t \mathbb{P}(\text{individu de taille t}) \times t$$

- Espérance de fonctions : $X \sim$ pile ou face

$$\mathbb{E}\left[(X+1)^2\right] = (1/2) \times (0+1)^2 + (1/2) \times (1+1)^2 = 5/2$$

- Plus compliqué : $(X, Z) = (\text{taille, poids})$

$$\text{IMC moyen : } \mathbb{E}\left[\frac{Z}{X^2}\right]$$

Cadre générique - apprentissage supervisé

- Couple de v.a. $= (X, Y) \sim P$ **inconnue**
- $X =$ vecteur d'entrée à valeurs dans $\mathcal{X}(\mathbb{R}^d)$, ici $d \gg 1$
- $Y =$ label/étiquette dans $\mathcal{Y} \subset \mathbb{R}$
- *A priori*, X modélise une information utile pour prédire Y
- Ex : $X = (\text{taille}, \text{alimentation}, \text{profession})$ et $Y = \text{poids}$
- Règle prédictive: $C : \mathcal{X} \to \mathcal{Y}$ choisie dans un ensemble $\mathcal{C}$ déterminé à l'avance
- Ex : prédicteur linéaire $C(x) = \beta^\top x + \alpha$
- Fonction de perte : $\ell : \mathcal{Y} \times \mathcal{Y} \to \mathbb{R}^+$
- La perte représente l'écart quantitatif entre notre prédiction et la réalité
- Elle dépend de la tâche que l'on se donne
- Risque perte moyenne

$$L(C) = \mathbb{E}\left[\ell(Y, C(X))\right]$$

- Objectif : trouver le prédicteur minimisant le risque

Exemple 1 - Classification binaire

- Exemple: Prédiction de l'état d'un système (normal *vs* anormal)
- $\mathcal{Y} = \{-1, +1\}$
- Fonction de perte binaire :

$$\ell(y, z) = \mathbb{1}_{\{y \neq z\}}$$

- Risque d'erreur :

$$L(g) = \mathbb{E}\left[\mathbb{1}_{\{Y \neq g(X)\}}\right] = \mathbb{P}\{Y \neq g(X)\}$$

- Le risque représente la **probabilité de se tromper** dans sa prédiction : il est naturel de chercher à le minimiser

Exemple 2 - Classification multi-classe

- Exemple: reconnaissance d'un caractère manuscrit
- $\mathcal{Y} = \{1, \ldots, M\}$
- Fonction de perte binaire

$$\ell(y, z) = \mathbb{1}_{\{y \neq z\}}$$

- Risque identique au cas binaire
- En pratique, plusieurs possibilités:
  - Un contre un : on entraîne un classifieur renvoyant une classe parmi les M possibles
  - Un contre tous : on entraine M classifieurs binaires permettant de détecter si un élément appartient à une classe en particulier ou au reste. Ensuite, les classifieurs votent et on prédit la classe majoritaire.

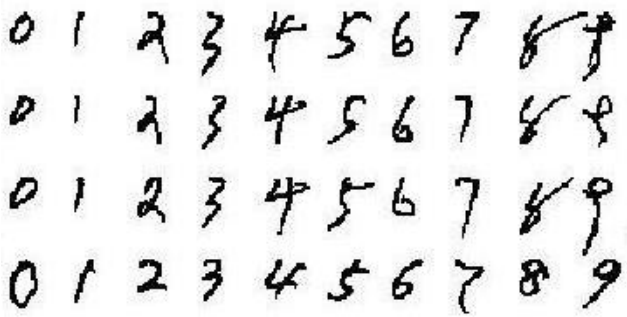

Exemple 3 - Régression

- Exemple: Prédiction de ventes
- $\mathcal{X}$ = vecteur de descripteurs (information financière, indicateurs macro-économiques, ...)
- $\mathcal{Y} = \mathbb{R}$
- Fonction de perte = erreur quadratique

$$\ell(y, z) = (y - z)^2$$

- Risque associé

$$\mathbb{E}\left[(g(X) - Y)^2\right]$$

- Solution optimale: $g^*(x) = \mathbb{E}\left[Y \mid X = x\right]$
- Bien que l'on ait une forme analytique pour la solution, la loi P de (X, Y) est inconnue donc on ne peut la calculer exactement !

Exemple 4 - Régression ordinale

- Exemple: design d'un moteur de recherche
- Label ordinal $\mathcal{Y} = \{1, \ldots, M\}$
- Différent de la classification multilabel car on a désormais une relation d'ordre
- ex: $1 \leq 2 \leq \ldots \leq M$ ("mauvais" vs "moyen" vs "bon")
- Fonction de perte quadratique

$$\ell(y, z) = (y - z)^2$$

- En pratique: régression + arrondi

De très nombreux problèmes...

- Moteurs de recommandation, filtrage collaboratif
- Graph-Mining, détection de communautés
- Analyse en Variables Latentes: (Kernel) PCA, ICA, NMF
- Règles d'association (*e.g.* algorithme *apriori*)
- Apprentissage par renforcement:
  exploration vs exploitation
- Analyse sémantique

Des succès dans de nombreuses applications...

- Reconnaissance de la parole
- Biométrie
- Publicité en ligne
- Détection de fraude
- Risque de crédit
- Aide au diagnostic médical
- Séparation de sources
- Yield management
- *etc.*

De très nombreuses technologies...

- **Machines à Vecteurs Supports**
- **Deep Learning**
- **Forêts Aléatoires, Boosting**
- **Bandits Stochastiques**
- Modèles graphiques: réseaux bayesiens/markoviens
- **K-means**, clustering spectral
- Indexation sémantique latente
- Apprentissage multi-tâche
- *etc.*

Et des contraintes et contextes variés...

- Données **fonctionnelles** (*e.g.* séries temporelles)
- Apprentissage "en ligne" *vs* apprentissage "batch"
- Nécessité d'**interpréter** les règles de décision
- Données et calculs **distribués**
- Apprentissage **semi-supervisé**
- *etc.*

Risque Empirique

En pratique

- La loi P de (X, Y) est inconnue
- Le risque associé à un classifieur l'est également
- On connaît des réalisations de P : ce sont nos données
- Données $= \{(X_1, Y_1), \ldots, (X_n, Y_n)\}$
- On approche le risque par son homologue empirique :

$$\widehat{L}_n(C) = \frac{1}{n}\left(\ell(Y_1, C(X_1) + \ldots + \ell(Y_n, C(X_n))\right)$$

- Au lieu de chercher C^* minimisant le vrai risque, on va chercher $\widehat{C}_n$:

$$\widehat{C}_n \in \arg\min_{C \in \mathcal{C}} \widehat{L}_n(C)$$

- On appelle $\widehat{C}_n$ minimiseur du risque empirique

Application : classification binaire (1)

- $X =$ (poids, taille), $Y =$ sexe (homme : -1, femme : $+1$)
- On considère pour $\mathcal{C}$ l'ensemble des classifieurs linéaires (centrés) :

$$\mathcal{C} = \left\{ \mathrm{sgn}(f(x)), \text{ tel que } f(x) = \langle x, \beta \rangle,\ \beta \in \mathbb{R}^d \right\}$$

- Fonction de perte : $\ell(y, z) = (y - z)^2$
- On considère cette perte pour l'instant car elle permet d'obtenir directement le minimiseur du risque empirique :

$$\widehat{C}_n = \mathrm{sgn}\left(\langle x, \widehat{\beta}_n \rangle \right),$$

où

$$\widehat{\beta}_n = \arg\min_{\beta \in \mathbb{R}^d} \sum_{i=1}^{n} (\langle X_i, \beta \rangle - Y_i)^2 \left(= \left(\mathbf{X}\mathbf{X}^\top \right)^{-1} \mathbf{X}^\top \mathbf{y} \right)$$

Application : classification binaire (2)

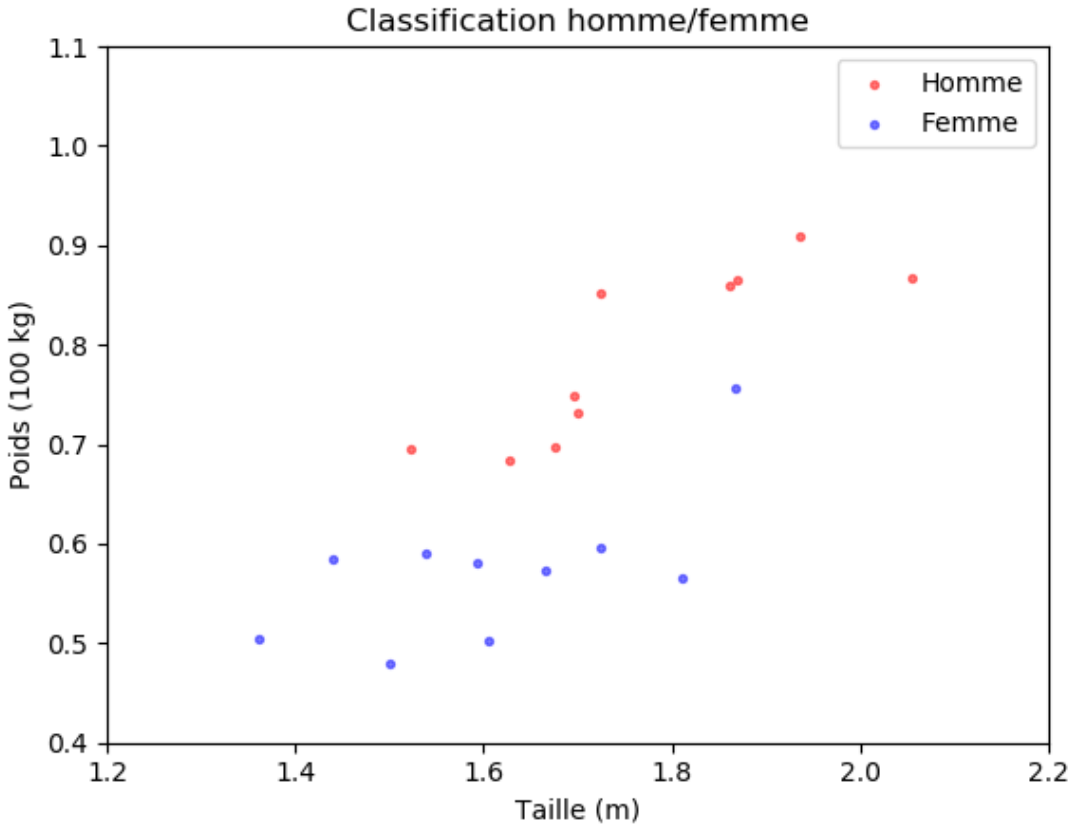

Application : classification binaire (2)

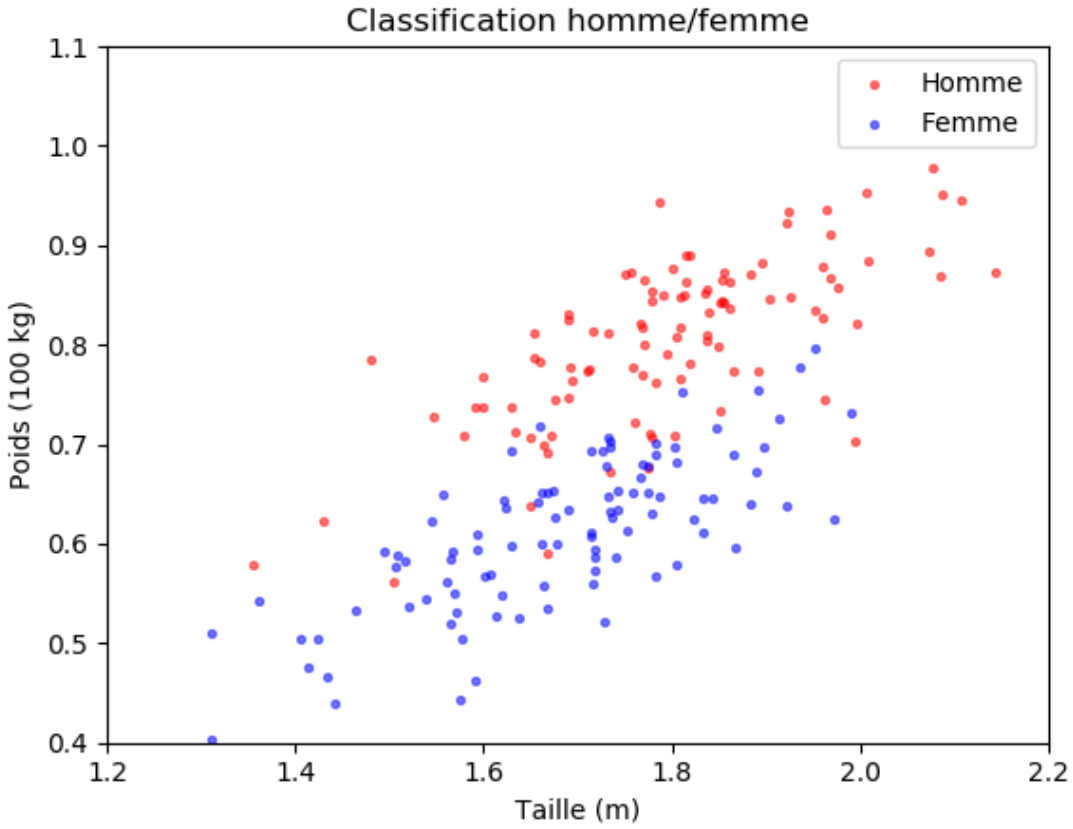

Application : classification binaire (2)

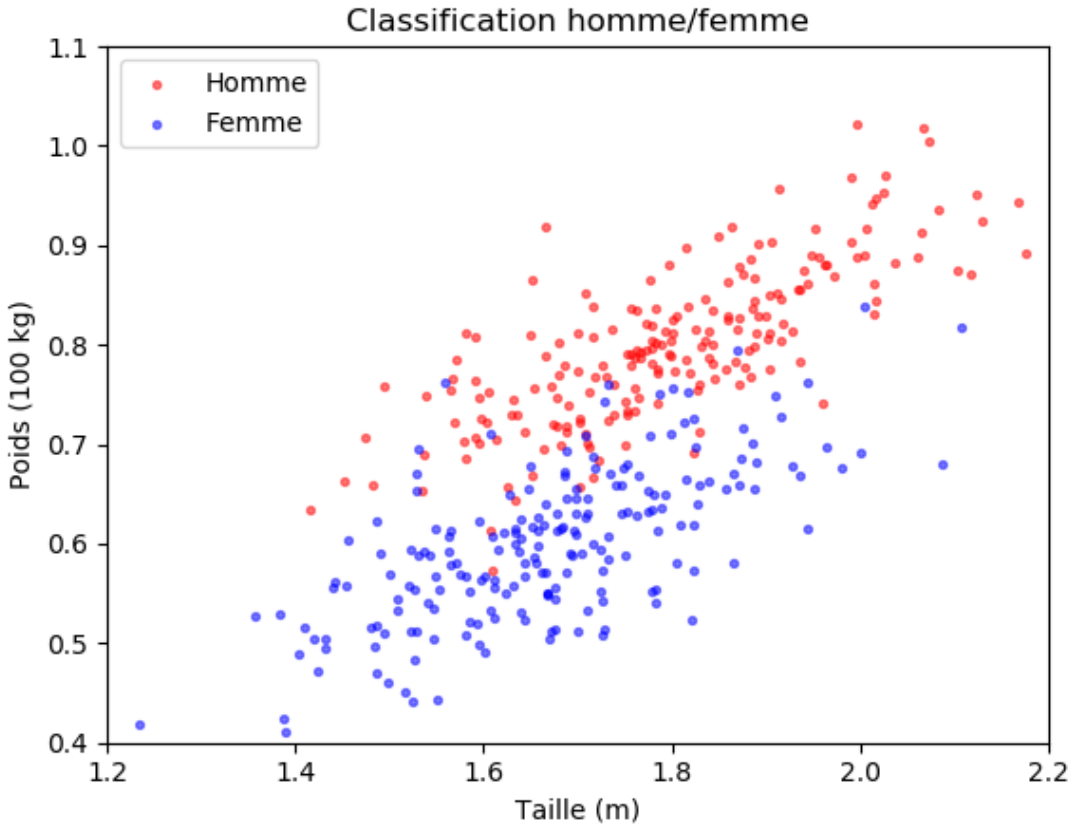

Application : classification binaire (2)

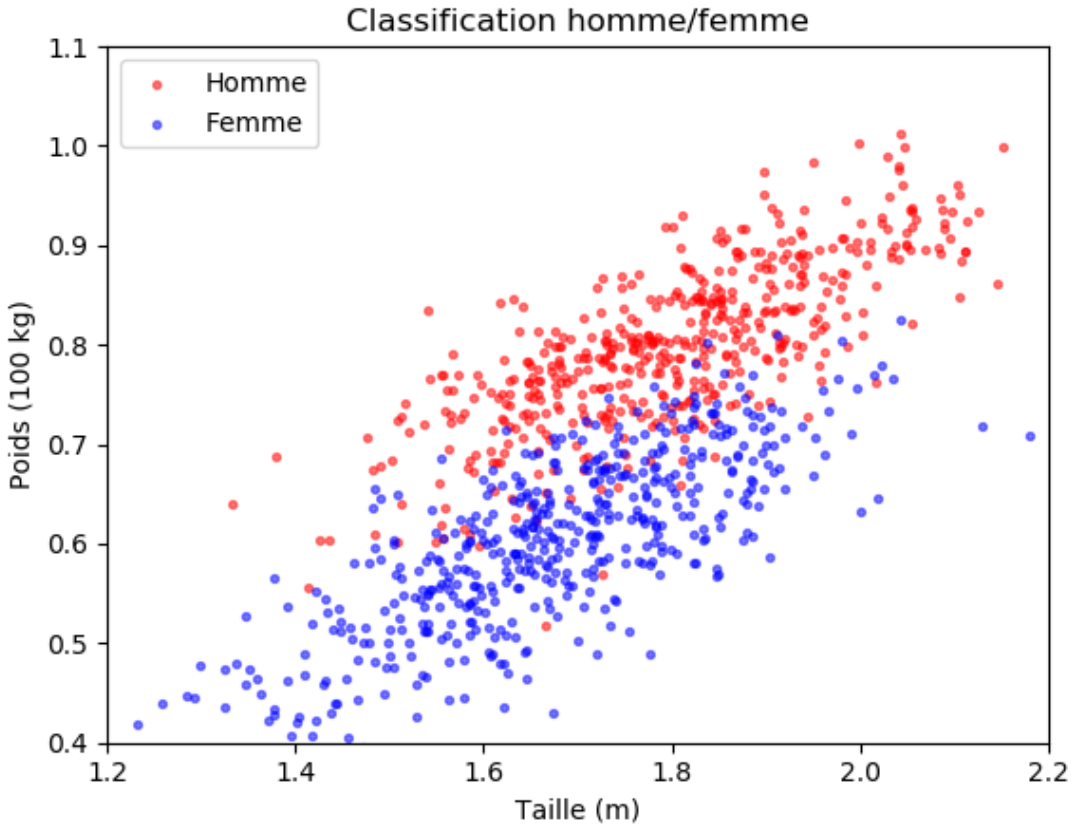

Application : classification binaire (2)

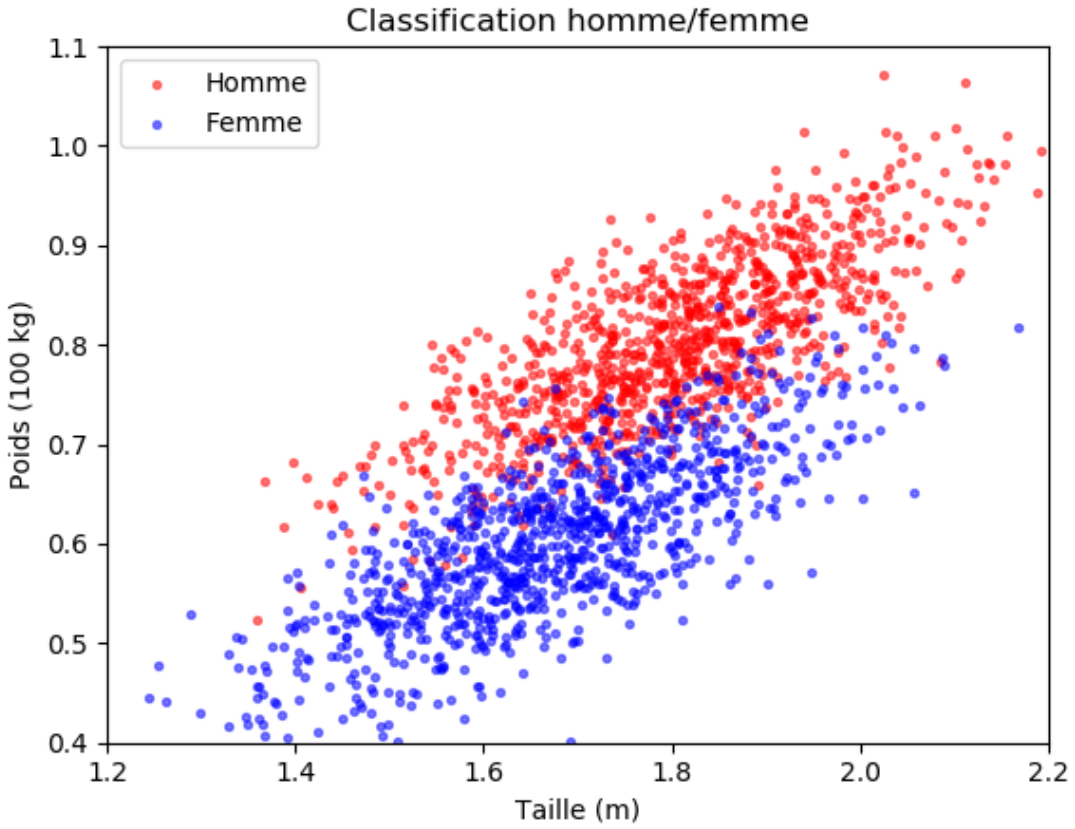

Application : classification binaire (2)

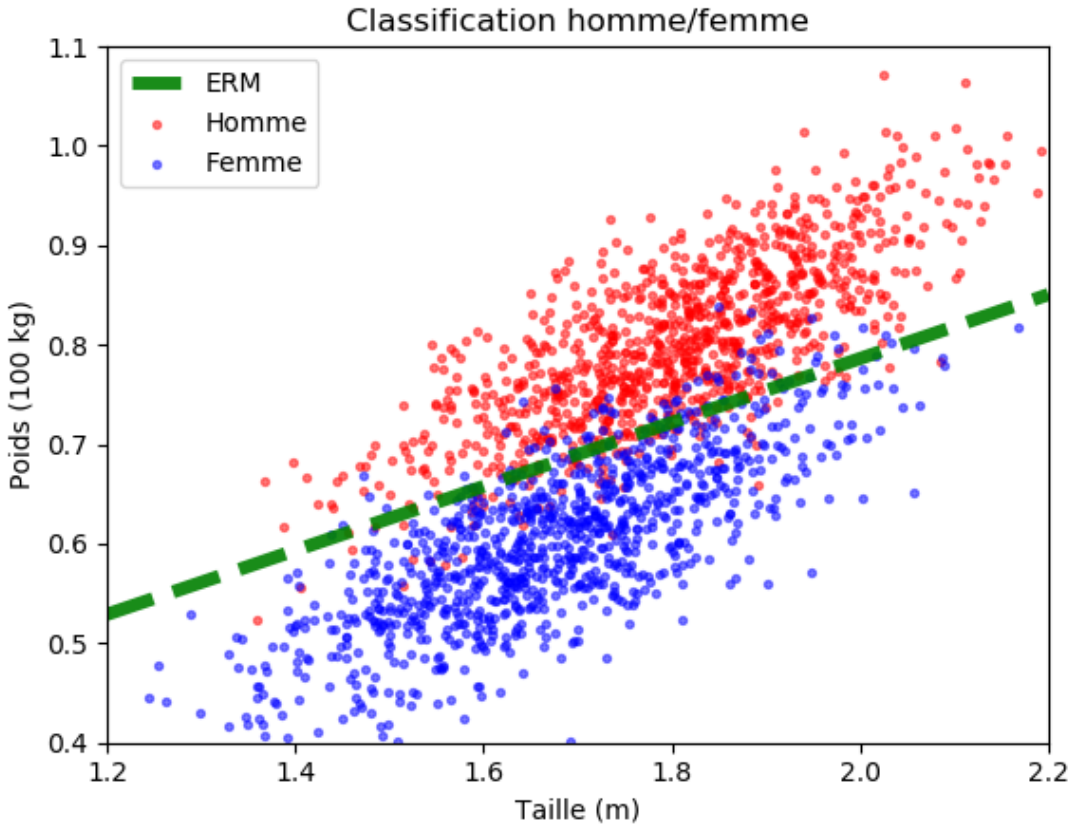

Application : classification binaire (2)

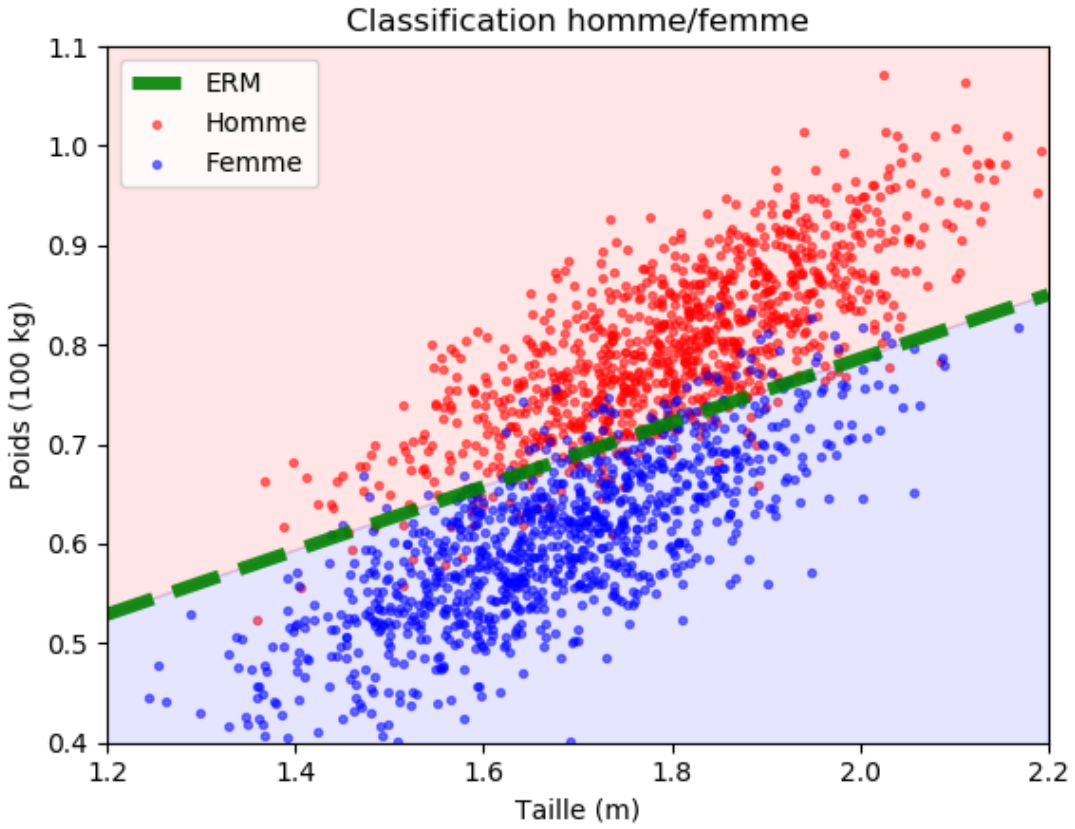

Risque vs. risque empirique (1)

- Couple de v.a. $(X, Y) \sim P$ inconnue
- $X =$ v.a. d'entrée à valeurs dans $\mathcal{X}$ (ex: $\mathbb{R}^d$ with $d >> 1$)
- $Y =$ label binaire, à valeurs dans $\mathcal{Y} = \{-1, +1\}$
- **Objectif:** construire un **classifieur**:
  $C : x \in \mathcal{X} \mapsto C(x) \in \{-1, 1\}$ minimisant le risque, parmi un ensemble de classifieurs $\mathcal{C}$

$$L(C) = \mathbb{E}\left[\mathbb{1}_{\{Y \neq C(X)\}}\right]$$

- Données $= D_n = \{(X_1, Y_1), \ldots, (X_n, Y_n)\}$ indépendantes et toutes tirées de la loi P

Risque vs. risque empirique (2)

- Idéalement, calculer $C^* = \arg\min_{C \in \mathcal{C}} L(C)$
- Le risque $L(.)$ est inconnu, car la loi P des variables (X, Y) l'est également
- On peut cependant déjà en tirer des informations intéressantes
- Soit $\eta(x) = \mathbb{P}(Y = +1 | X = x)$ **probabilité a posteriori**
- On pose $p = \mathbb{P}(Y = +1)$ (la proportion de labels positifs)
- On peut montrer que le classifieur optimal vérifie

$$C^*(x) = \begin{cases} 1 & \text{si } \eta(x) > 1/2 \\ -1 & \text{sinon.} \end{cases}$$

- On prédit le label le plus probable au vu de l'observation $X = x$, **classifieur de Bayes**
- Risque minimum théorique: $L^* = L(C^*) = 1/2 - \mathbb{E}[|\eta(X) - 1/2|]$
- La distribution de $\eta(X)$ autour de $1/2$ régit la difficulté du problème!

Minimisation du Risque d'Erreur Théorique

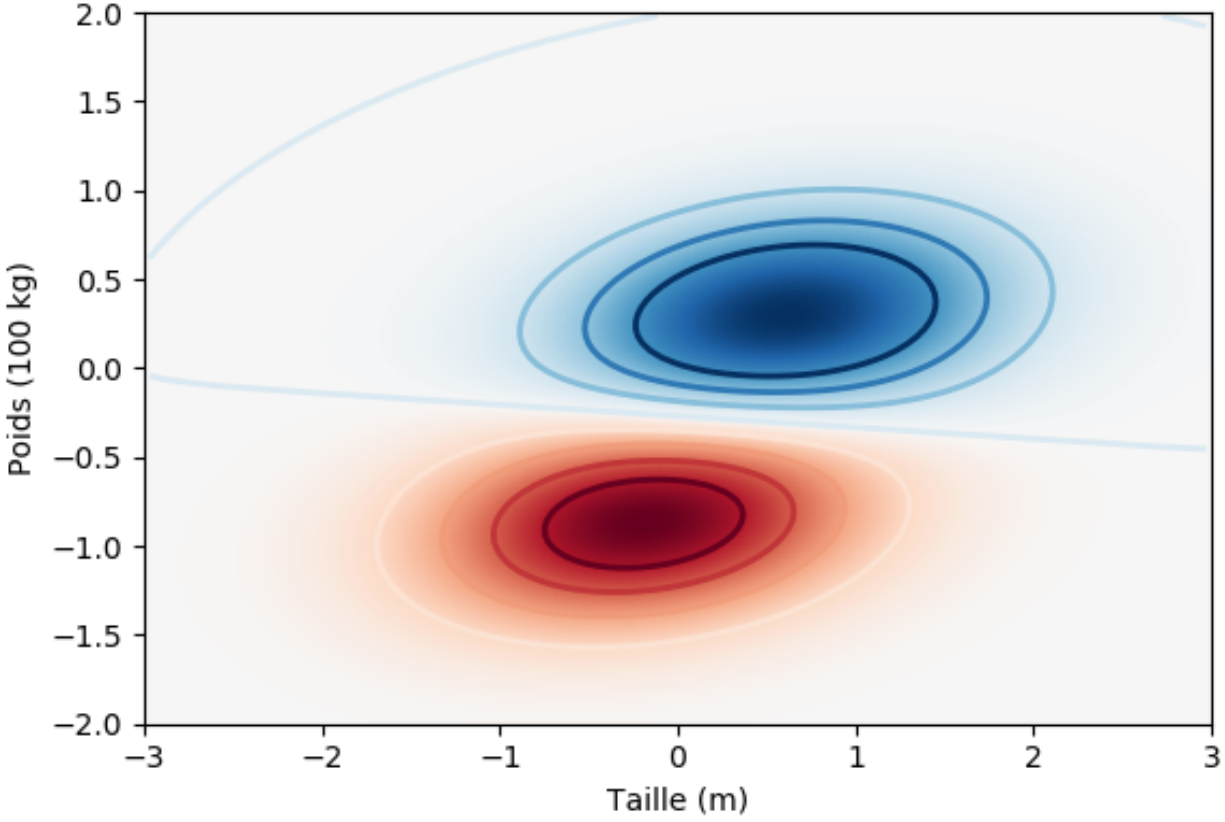

Figure: Probabilité *a posteriori*.

Minimisation du Risque d'Erreur Théorique

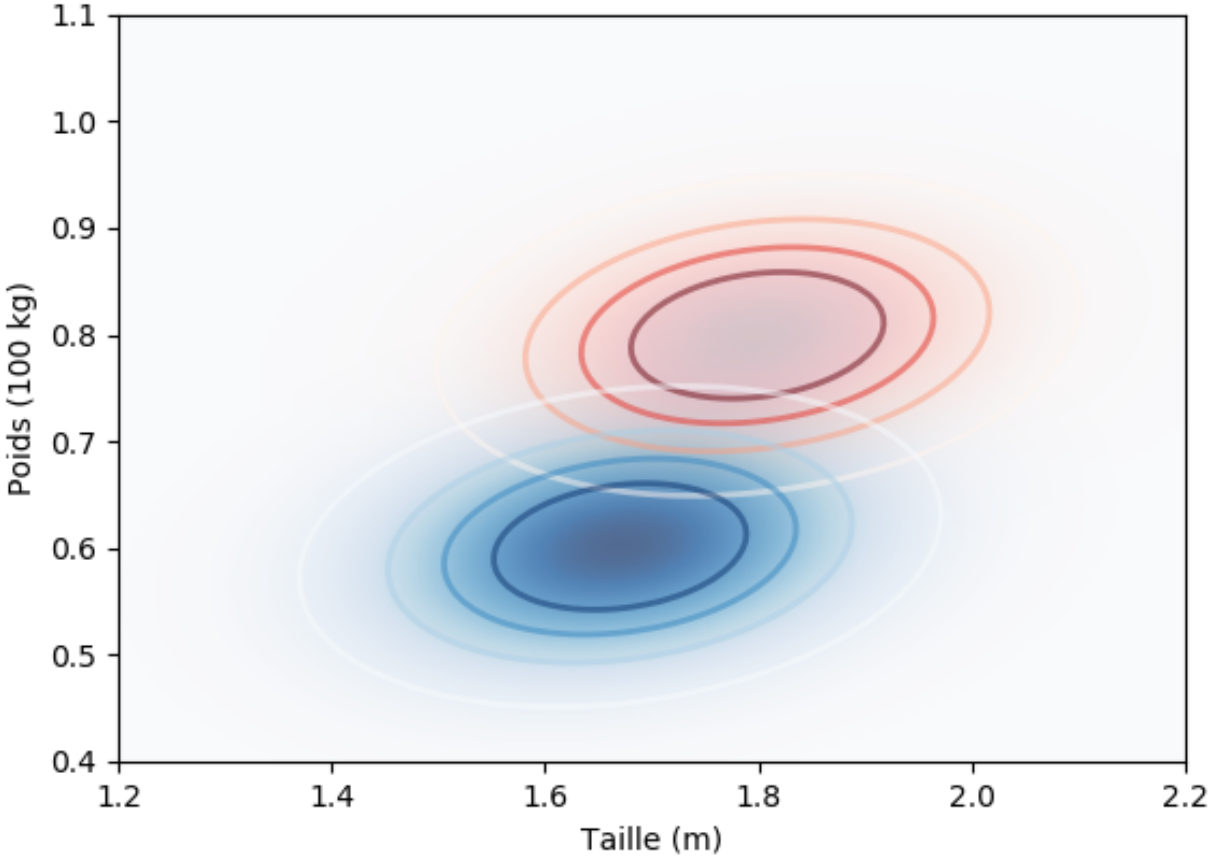

Figure: Écart entre les distributions conditionnelles.

Minimisation du Risque d'Erreur Théorique

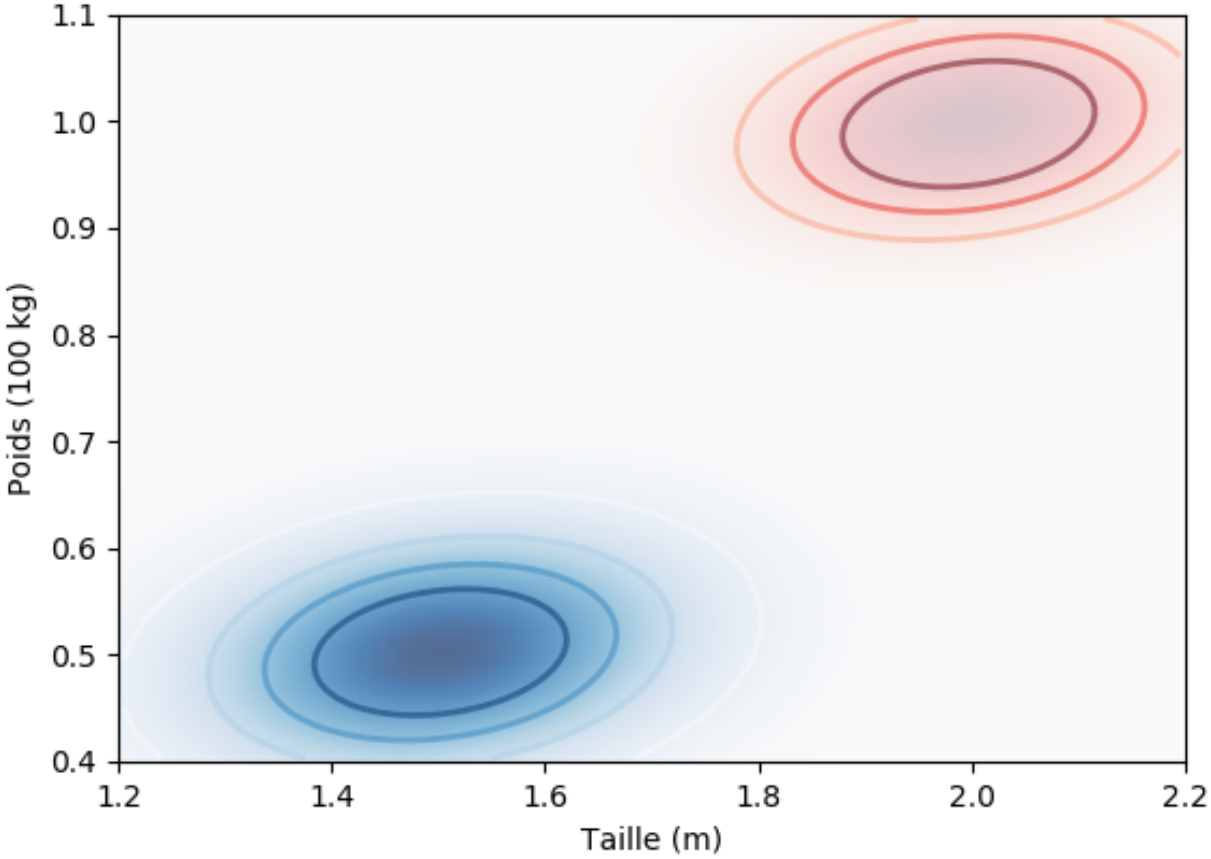

Figure: Cas simple.

Minimisation du Risque d'Erreur Théorique

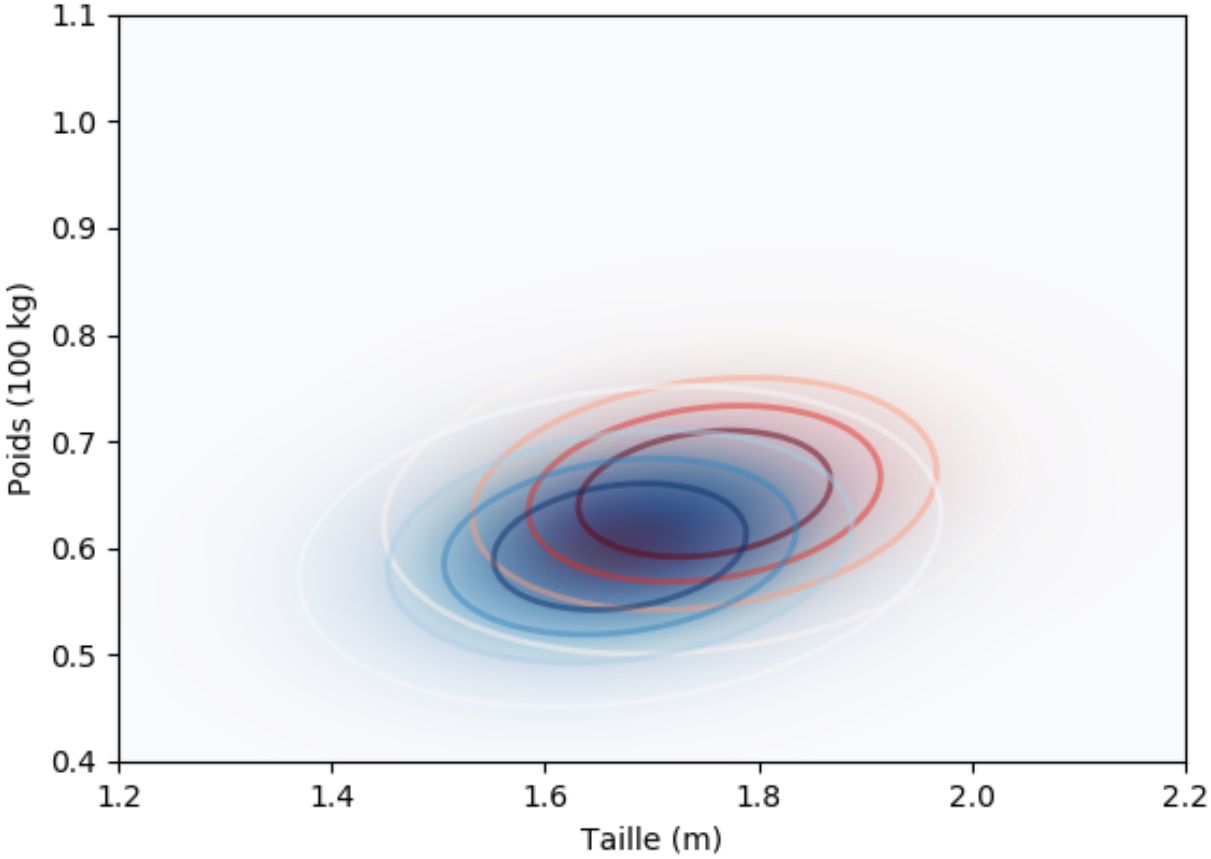

Figure: Cas difficile.

Le surapprentissage

Minimisation du Risque Empirique (ERM)

- On ne connaît pas la loi P mais on observe des réalisations de cette loi
- Données d'apprentissage $D_n = \{(X_1, Y_1), \ldots, (X_n, Y_n)\}$
- Candidat: $C : \mathcal{X} \to \{-1, 1\}$ appartenant à une classe $\mathcal{C}$
- Risque **empirique** = Erreur d'apprentissage

$$\widehat{L}_n(C) = \frac{1}{n} \sum_{i=1}^{n} \mathbb{1}_{\{Y_i \neq C(X_i)\}}$$

- Manière naturelle d'approcher le risque réel avec les informations disponibles
- On va désormais chercher le classifieur de l'ensemble $\mathcal{C}$ qui minimise le risque empirique
- Solution **"minimiseur du risque empirique"**:

$$\widehat{C}_n = \arg\min_{C \in \mathcal{G}} \widehat{L}_n(C)$$

- Le classifieur est idéal pour les données que l'on possède (les **données d'apprentissage**)
- Qu'en est-il des **données** (X, Y) **à venir** ?

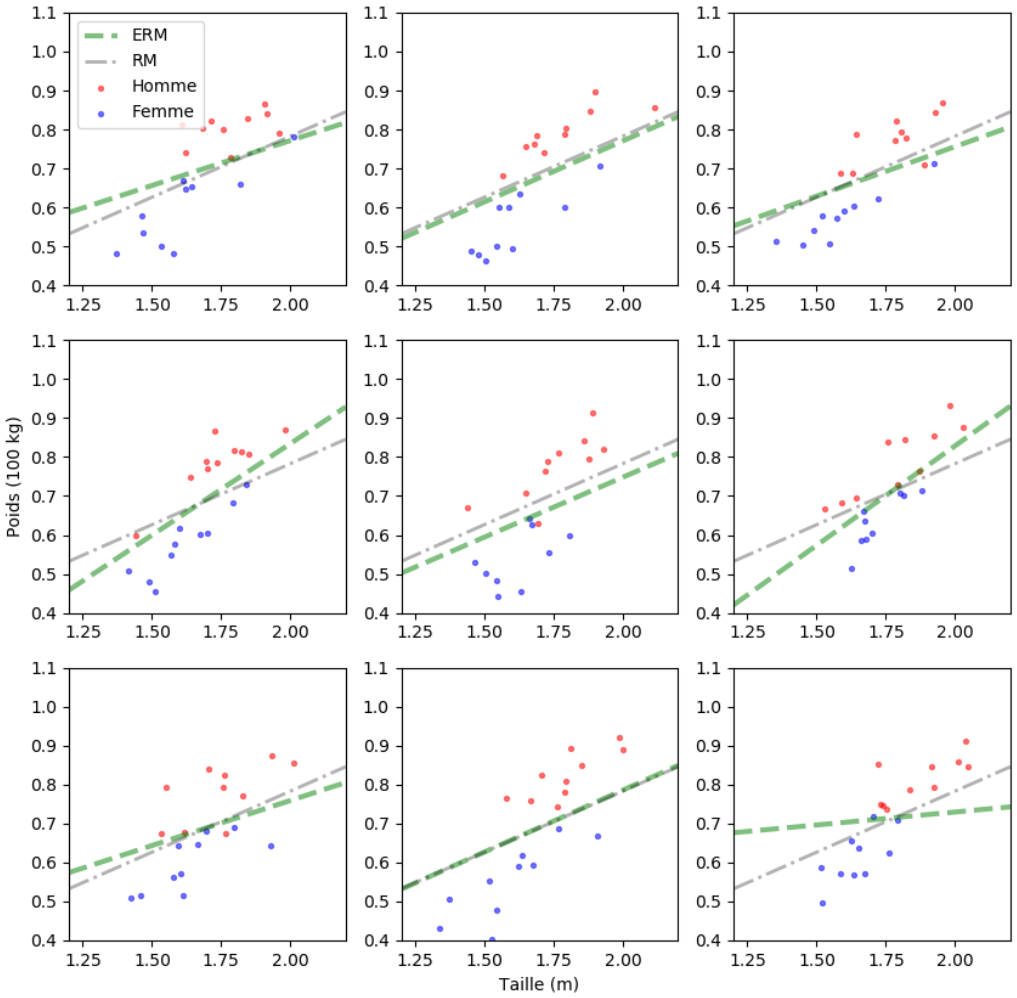

Figure: ERM vs. RM sur 20 données.

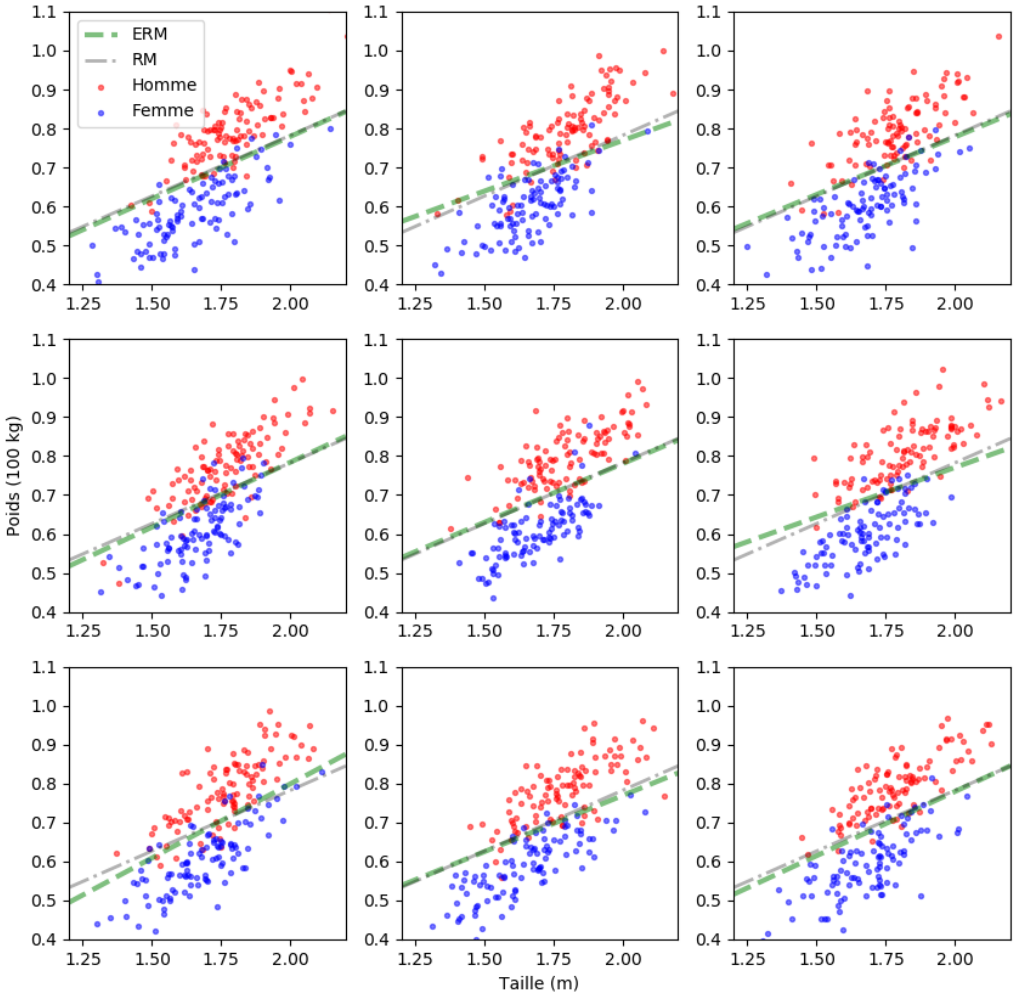

Figure: ERM vs. RM sur 200 données.

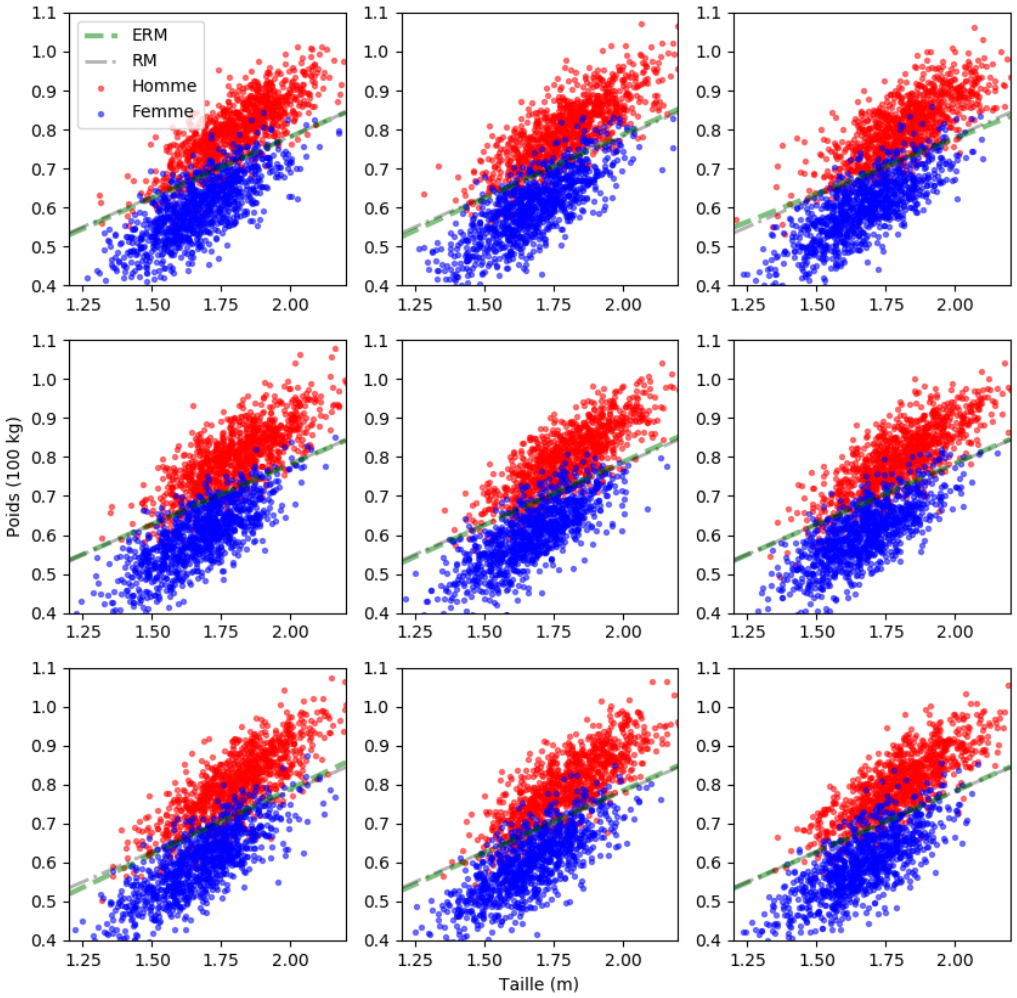

Figure: ERM vs. RM sur 2000 données.

ERM - Heuristique

- L'apprentissage peut fonctionner lorsque $\widehat{L}_n(C)$ est proche de $L(C)$, **pour chaque classifieur** dans $\mathcal{C}$
- Pour un classifieur C fixé, $\widehat{L}_n(C) \to L(C)$ lorsque le nombre n d'exemples croît (Loi des grands nombres, théorème de la limite centrale, *etc.*)
- Si le nombre d'exemples est limité, comment s'assurer que l'on n'apprend pas du bruit ?
- La théorie de Vapnik-Chervonenkis fournit des garanties lorsque l'ensemble $\mathcal{C}$ n'est **pas trop complexe**, quelle que soit la distribution des données (X, Y)

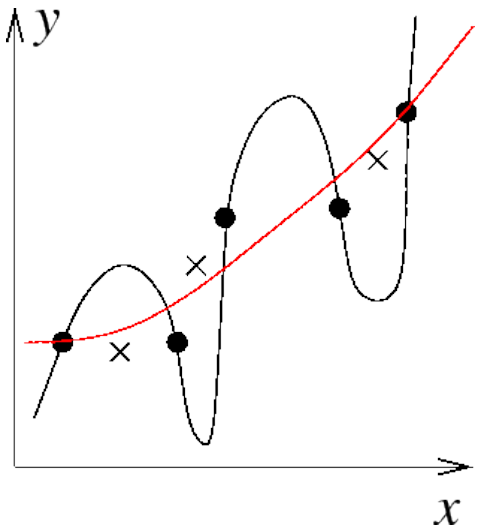

ERM - Eléments de théorie (1)

- Ce qui nous intéresse en réalité n'est pas $\widehat{L}_n(\widehat{C}_n)$ (on sait déjà que $\widehat{C}_n$ est le meilleur candidat) mais plutôt $L(\widehat{C}_n)$, le vrai risque de notre classifieur
- Sous quelles conditions peut-on garantir que l'apprentissage fonctionne? C'est à dire que $L(\widehat{C}_n)$ est proche de L^*?
- Cette proximité est quantifiée par $L(\widehat{C}_n) - L^*$: c'est l'écart entre le risque du classifieur obtenu et le risque du meilleur classifieur possible

ERM - Eléments de théorie (2)

- La décomposition **"biais-variance"** de cette erreur nous apporte une intuition :

$$L(\widehat{C}_n) - L^* \leq 2 \sup_{C \in \mathcal{C}} |L(C) - \widehat{L}_n(C)| + \inf_{C \in \mathcal{C}} L(C) - L^*$$

- Premier terme :
  - Écart maximal entre le risque empirique et le vrai risque parmi les éléments de $\mathcal{C}$
  - Plus $\mathcal{C}$ est complexe, plus cette erreur risque d'être grande
- Deuxième terme :
  - Erreur commise par le meilleur classifieur possible dans $\mathcal{C}$
  - Plus $\mathcal{C}$ est complexe, plus cette erreur est petite
  - Ce terme ne dépend que de l'ensemble $\mathcal{C}$ (biais), **pas des données d'apprentissage**
- Il y a un compromis à trouver entre la complexité de $\mathcal{C}$ et le nombre de données à notre disposition
- Le 1er terme (estimation) peut être contrôlé au moyen de résultats de **concentration**

ERM - Eléments de théorie

- La "complexité" de l'ensemble $\mathcal{C}$ régit le compromis "biais-variance"

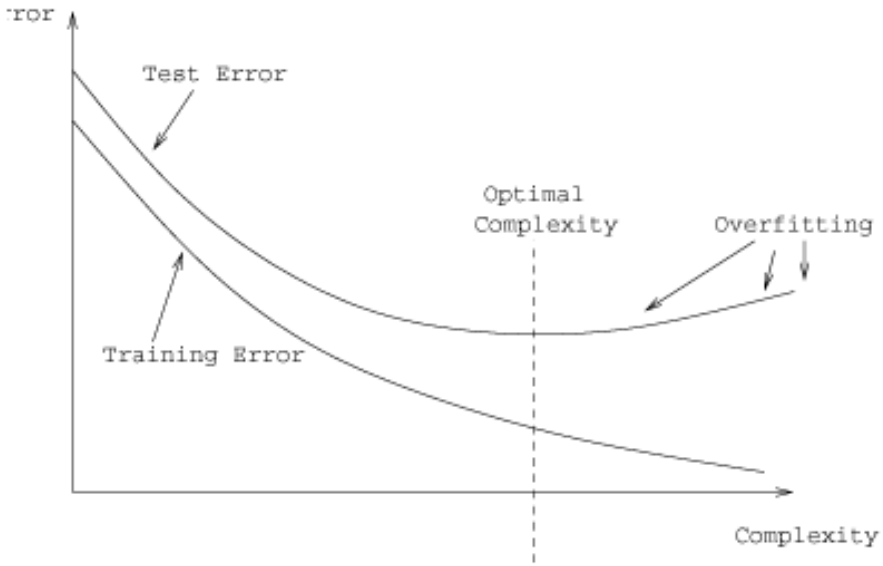

- Notion de **complexité combinatoire** introduite par Vapnik et Chervonenkis dans les années 60

Théorie de l'Apprentissage Statistique

A. Chervonenkis & V. Vapnik

Théorie de Vapnik et Chervonenkis

- Inégalité de concentration: avec *forte probabilité* :

$$\sup_{g \in \mathcal{G}} \mid L_n(g) - L(g) \mid \lesssim C\sqrt{\frac{V}{n}}$$

- V est la VC-dimension de $\mathcal{C}$: elle quantifie la complexité de $\mathcal{C}$
- La VC-dimension d'un ensemble $\mathcal{C}$ est le nombre maximum d'observations pouvant être séparées parfaitement grâce aux classifieurs de $\mathcal{C}$, **quelques soient les assignations** des labels au départ

VC dimension des classifieurs linéaires

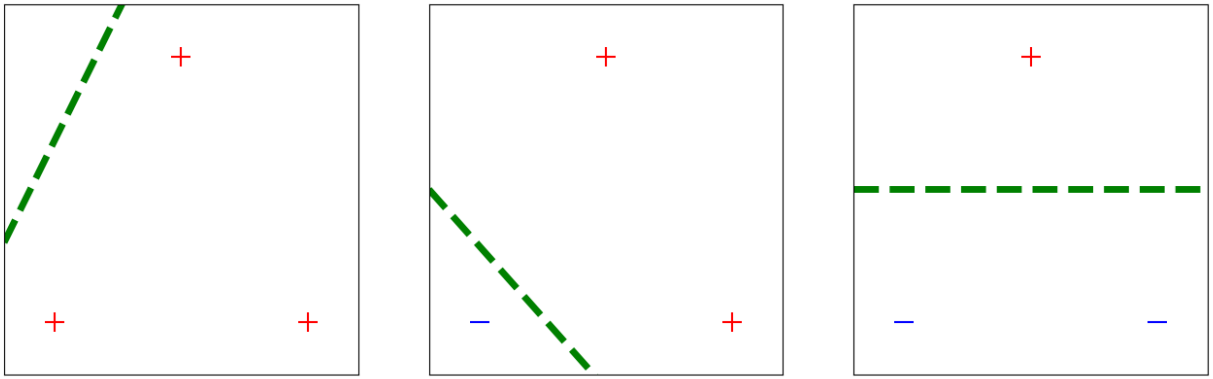

- Les classifieurs linéaires séparent parfaitement 3 observations
- Leur VC dimension est au moins de 3

VC dimension des classifieurs linéaires

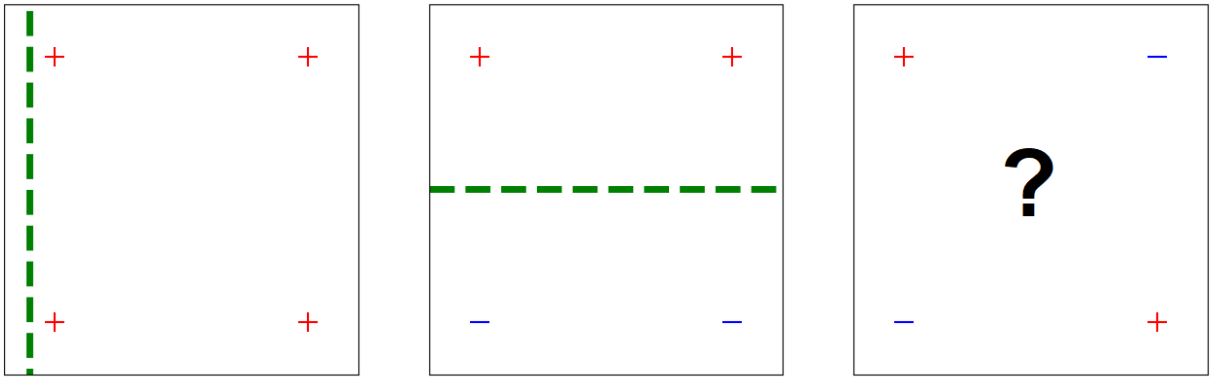

- Les classifieurs linéaires ne peuvent pas séparer parfaitement toutes les assignations pour 4 observations
- Leur VC dimension est exactement égale à 3
- Ici, des classifieurs quadratiques pourraient séparer parfaitement (VC dim $= 6$)

ERM - Eléments de théorie

- La théorie de Vapnik et Chervonenkis permet de contrôler l'erreur de généralisation
  - des règles **linéaires/quadratiques/paramétriques** (**analyse discriminante linéaire/quadratique**, **SVM linéaires**, **réseaux de neurones**)
  - des règles décrites par des **arbres de décision** (algorithme CART)
- Elle ne permet pas d'expliquer les capacités de généralisation des **SVM non linéaires**, des **techniques d'agrégation** (boosting, forêts aléatoires)
- L'inégalité est **très** large : elle ne doit pas être vue comme une manière fiable d'estimer l'erreur de test
- Elle fournit cependant une vitesse (comment l'erreur évolue en fonction du nombre d'observation ou de la complexité) et la philosophie générale du surapprentissage

Un modèle simple : la méthode des plus proches voisins

Méthodes des plus proches voisins (1)

- Classification binaire
- Données $= \{(X_1, Y_1), \ldots, (X_n, Y_n)\}$
- Nouveau point X' : quelle prédiction pour Y' ?
- Méthode des K plus proches voisins :
  - On détermine les K points les plus proches de X' : $X_{i_1}, \ldots, X_{i_K}$
  - Notre prédiction : la moyenne de leurs labels

$$\widehat{Y}' = \frac{1}{K}\left(Y_{i_1} + \ldots + Y_{i_K}\right)$$

- Pour éviter les égalités, on choisit K impair

Méthode des plus proches voisins (2)

- Avantages :
  - Pas de modèle ou de connaissance *a priori* nécessaire
  - Entraînement du modèle quasi-instantané
- Inconvénients :
  - Nécessite **beaucoup** de données en grande dimension (fléau de la dimension)
  - Temps de prédiction potentiellement long (il faut trouver les points les plus proches)
  - Souvent mauvais prédicteur si la nouvelle donnée est trop éloignée des données d'apprentissage
  - Quelle métrique ?

Les plus proches voisins sur notre problème

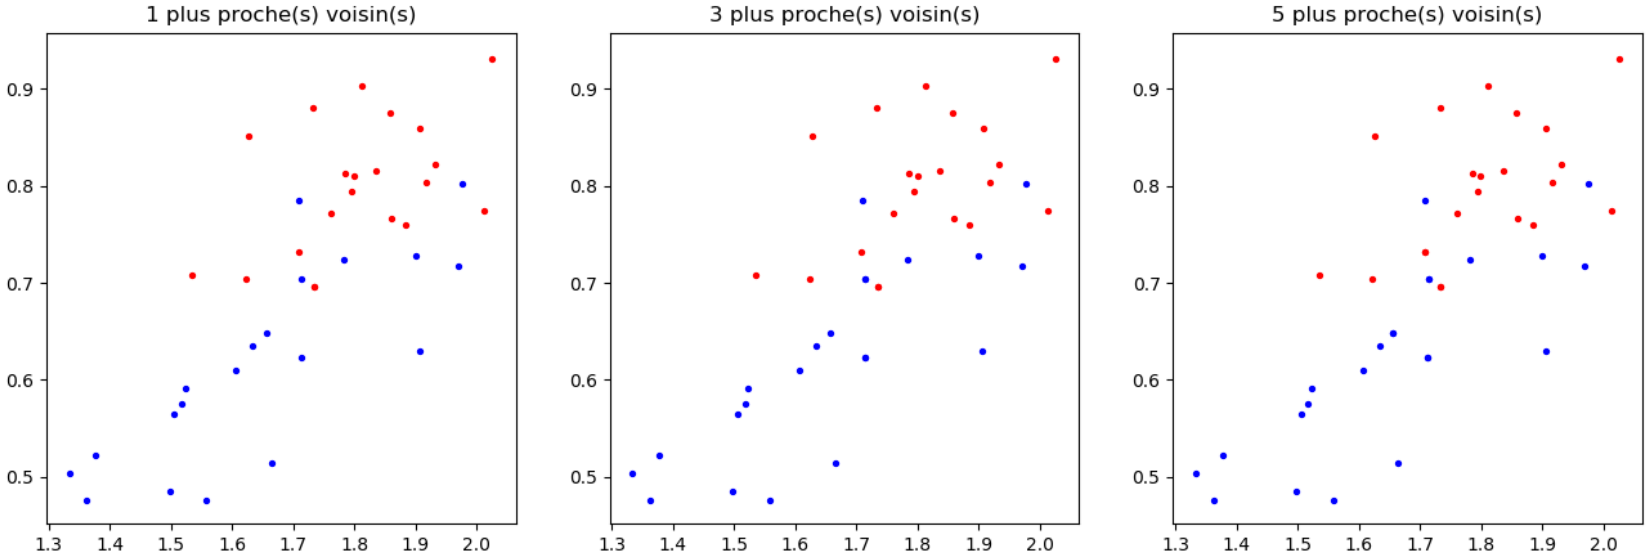

Les plus proches voisins sur notre problème

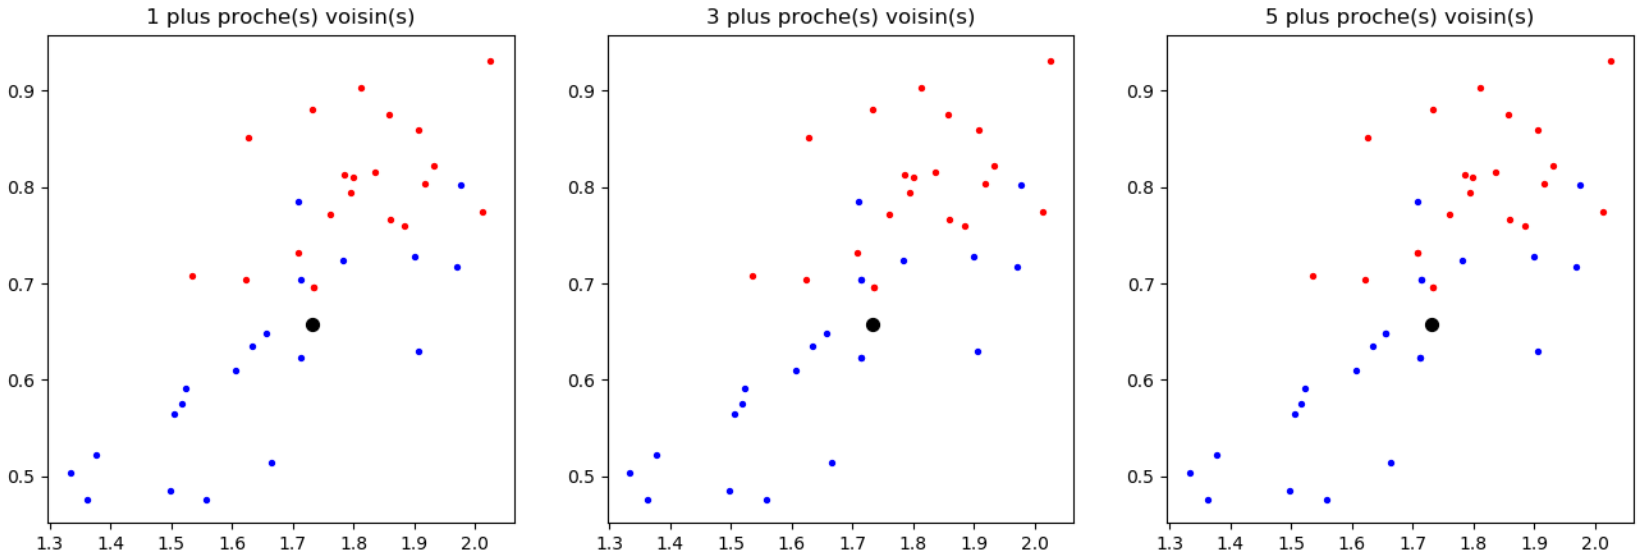

Les plus proches voisins sur notre problème

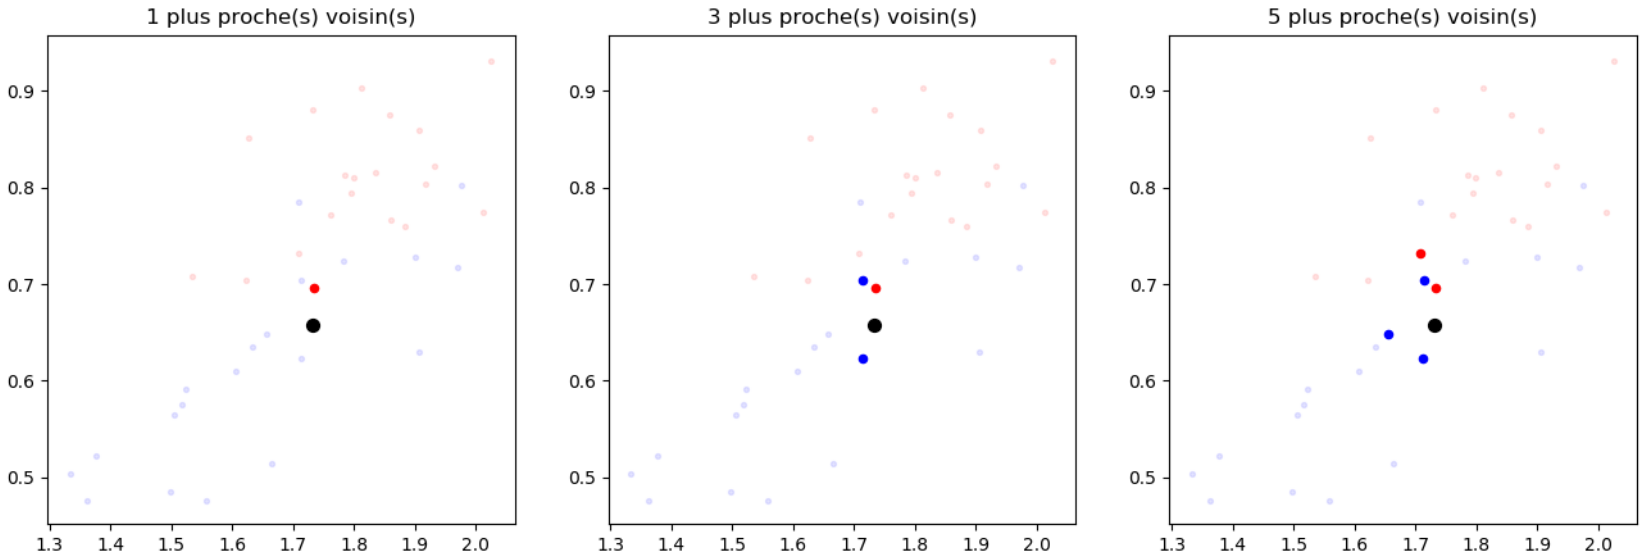

Les plus proches voisins sur notre problème

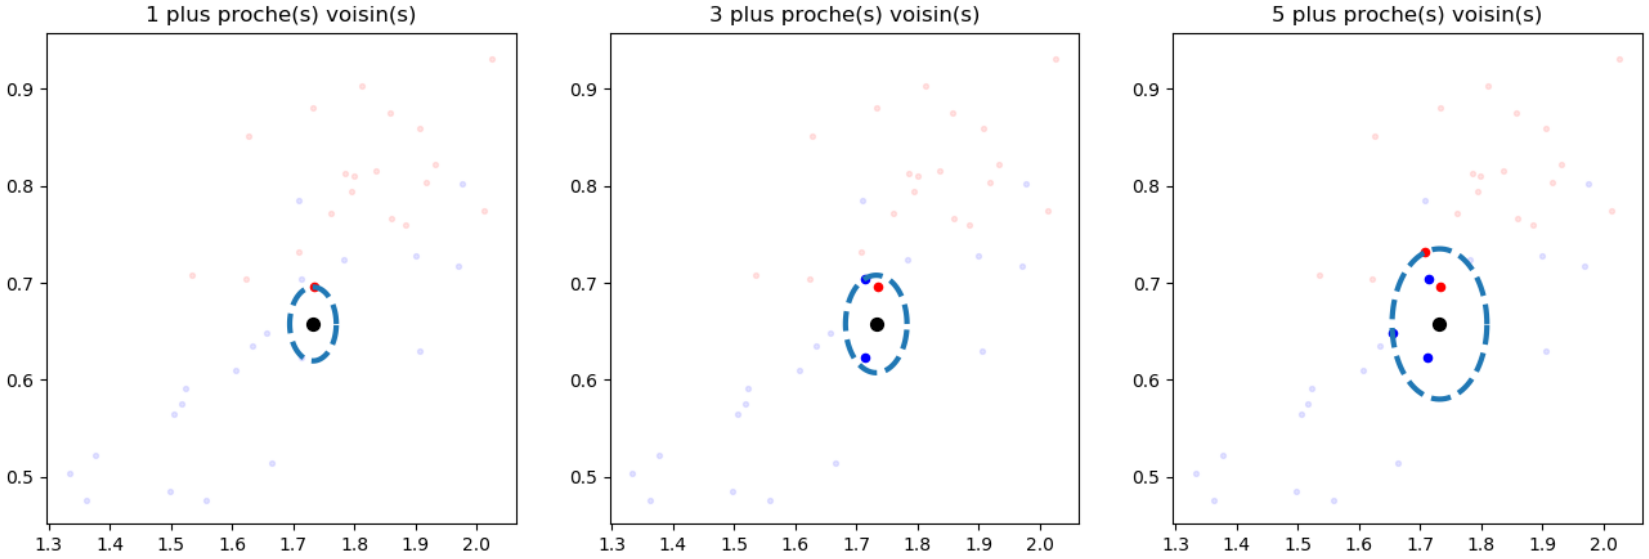

Les plus proches voisins sur notre problème

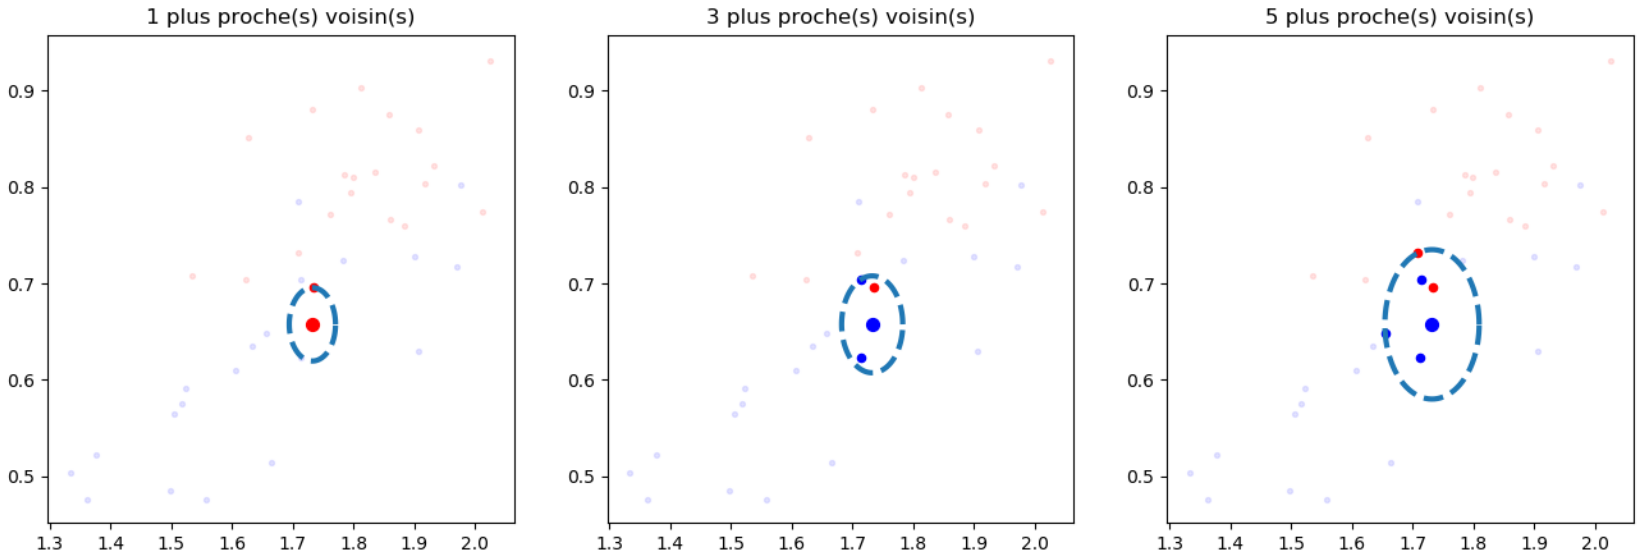

Éviter le surapprentissage

En théorie...

- La minimisation du risque empirique apporte un fondement théorique permettant de dériver de nombreuses méthodes
- Comme Vapnik et Chervonenkis l'ont souligné, elle présente un risque lorsque la complexité de la méthode n'est pas adaptée à la quantité de données disponibles
- Si la théorie ne permet pas de calculer l'erreur de test, comment faire en pratique pour l'évaluer ?

Il existe principalement 3 méthodes pour évaluer l'erreur de test :

- Le découpage entraînement-validation-test
- La validation croisée
- Le *bootstrap*

Régler le bon niveau de complexité

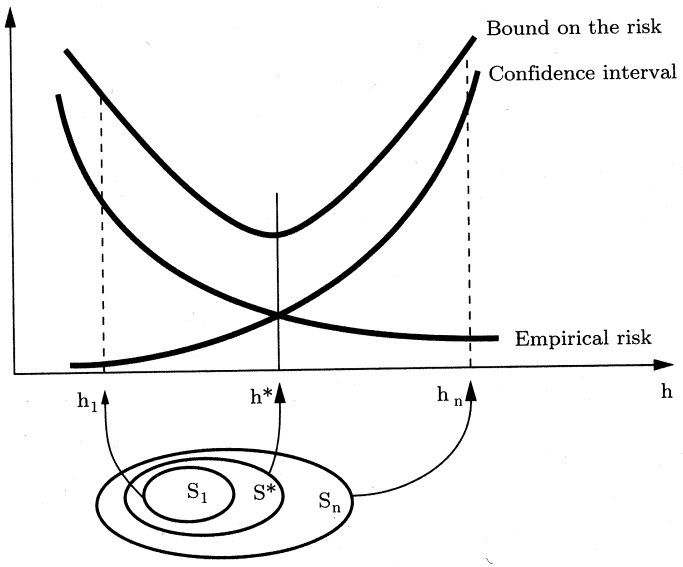

Exemples:

- le nombre de voisins dans les "k plus proches voisins"
- le nombre de feuille terminales d'un arbre de décision
- le nombre de vecteurs support d'un SVM
- le noyau d'un SVM non linéaire
- le nombre de couches d'un réseau de neurones

Méthodes pour l'évaluation du risque, la sélection de modèle

- L'apprentissage est réalisé à partir d'exemples

$$\mathcal{D}_n = \{(X_1, Y_1), \ \ldots, \ (X_n, Y_n)\}$$

- L'erreur d'apprentissage n'est pas un bon estimateur de l'erreur!

$$\widehat{L}_n(\widehat{C}_n) = \frac{1}{n} \sum_{i=1}^{n} \mathbb{1}_{\{Y_i \neq \widehat{C}_n(X_i)\}}$$

- Elle se réduit à 0 dès que l'ensemble $\mathcal{C}$ est suffisamment complexe
- Surapprentissage et faible capacité de généralisation
- Notre objectif est double
  - Sélection de Modèle: choisir le meilleur modèle parmi des modèles en compétition
  - Evaluation du Risque: pour un modèle donné, estimer l'erreur de prédiction

Découpage

- Diviser les données en trois parties:

  Apprentissage - Validation - Test

- Typiquement: 50% - 25% - 25%
- On considère $K \geq 1$ différentes classes de modèles candidates: $\mathcal{C}_1, \ldots, \mathcal{C}_K$
- Ex : $\mathcal{C}_1 = 1$ plus proche voisin, $\mathcal{C}_2 = 3$ plus proches voisins, *etc.*
  - Pour chaque catégorie $k \in \{1, \ldots, K\}$, on détermine le classifieur optimal par rapport au critère que l'on s'est fixé
  - On obtient K classifieur candidats : $\widehat{C}^{(1)}, \ldots, \widehat{C}^{(K)}$
  - Utiliser les données d'entraînement pour les évaluer n'est pas pertinent (ex: 1 plus proche voisin a toujours une erreur d'entraînement nulle)
  - On utilise donc des "nouvelles" données pour trouver le meilleur : les données de validation
  - On estime finalement l'erreur de test du classifieur obtenu grâce aux données de test

Validation Croisée

- Le découpage réduit la quantité de données disponibles lors de l'entraînement
- Soit $K \geq 1$ (typiquement 5), "K-fold cross-validation"
- Diviser aléatoirement les données en K parties égales
- Pour tout $k \in \{1, \ldots, K\}$,
  - apprendre $\widehat{C}^{(-k)}$ à partir de toutes les données sauf celles de la k-ième partie
  - calculer l'erreur réalisée par $\widehat{C}^{(-k)}$ sur les données de la k-ième partie
- Moyenner les K quantités
  $\rightarrow$ estimateur de l'erreur par validation croisée

L’apprentissage non-supervisé

Un exemple non-supervisé : k-means (1)

- Apprentissage non-supervisé : on possède des données $X_1, \ldots, X_n$ mais elles ne sont pas étiquetées
- On cherche à apprendre une structure dans les données, par exemple des *clusters*
- *Clustering* : trouver les zones de forte concentration
- On définit souvent les *clusters* avec les centroïdes
- Comme pour les plus proches voisins, un point appartient au *cluster* associé au centroïde le plus proche

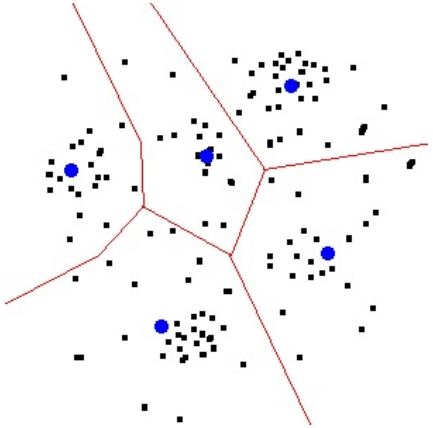

Figure: Clustering de points en 2d et centroïdes associés (bleu).

Un exemple non-supervisé : k-means (2)

- *k-means* : on cherche k centroïdes afin que les points soient concentrés dans les *clusters*
- Même sans étiquette, on peut toujours définir une fonction de perte (et un risque)
- On considère que la "prédiction" $c(X)$ associé à une donnée est le centroïde le plus proche
- En utilisant la perte quadratique, cela revient à trouver les centroïdes minimisant :

$$\min_{c_1,\ldots,c_k} \|X_1 - c(X_1)\|^2 + \ldots + \|X_n - c(X_n)\|^2$$

- On cherche les k centroïdes minimisant l'**inertie intra-cluster**

Il est très difficile de trouver les *clusters* optimaux !

Un exemple non-supervisé : k-means (3)

La méthode *k-means* permet de trouver une approximation raisonnable de cet optimum.

- Initialisation : on associe chaque centroïde à une donnée tirée au hasard
- Ensuite, on alterne :
  - Assignation : on trouve le centroïde associé à (le plus proche de) chaque donnée
  - Mise à jour : on met à jour chaque centroïde avec la moyenne des points qui lui sont associés
- On s'arrête lorsque les centroïdes ne changent plus

Un exemple non-supervisé : k-means (3)

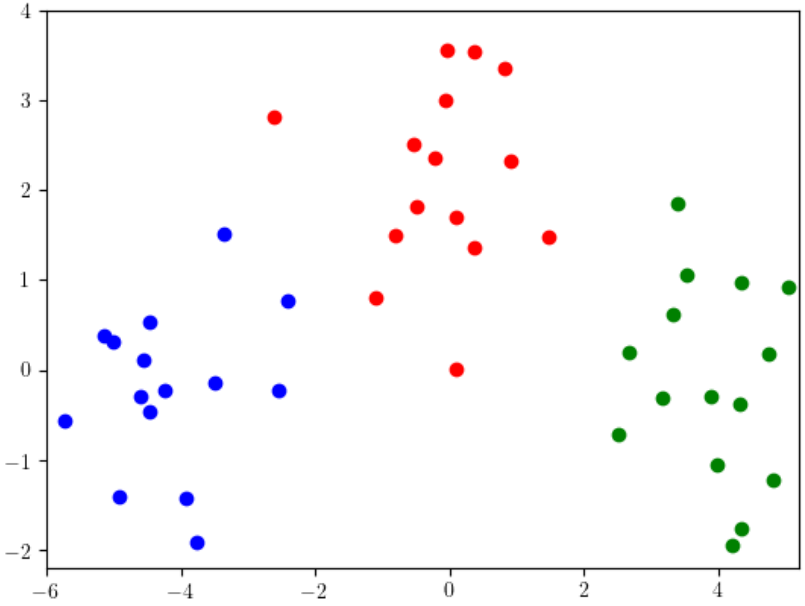

Figure: Points générés selon un mélange de 3 gaussiennes.

Un exemple non-supervisé : k-means (3)

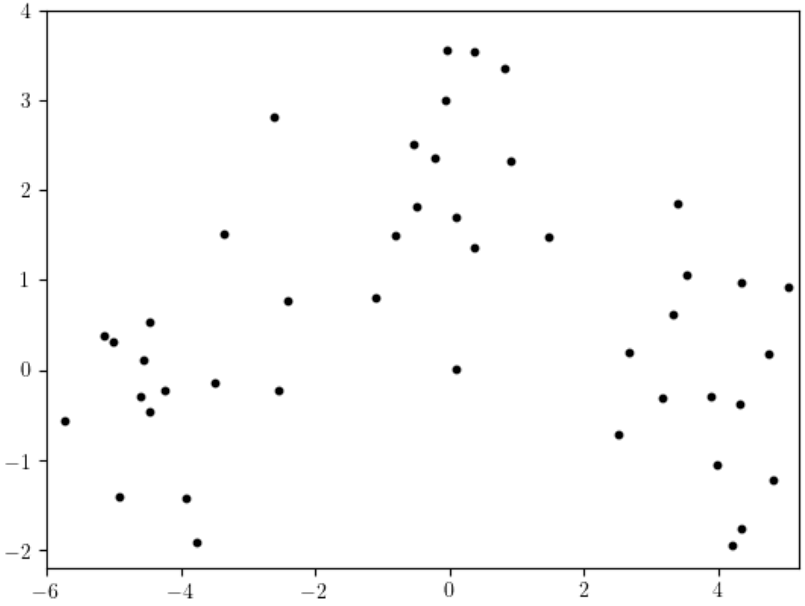

Figure: On ignore les labels.

Un exemple non-supervisé : k-means (3)

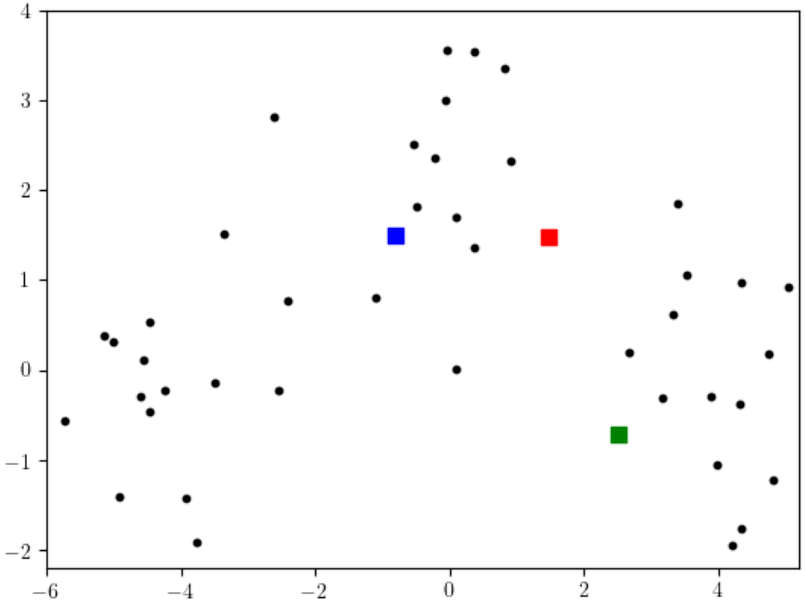

Figure: Centroïdes initialement tirés au hasard.

Un exemple non-supervisé : k-means (3)

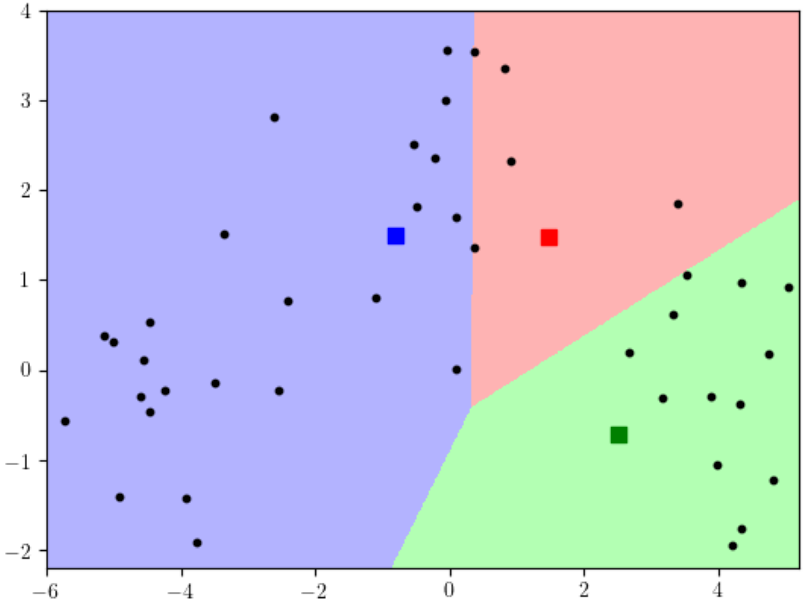

Figure: Clusters associés aux centroïdes.

Un exemple non-supervisé : k-means (3)

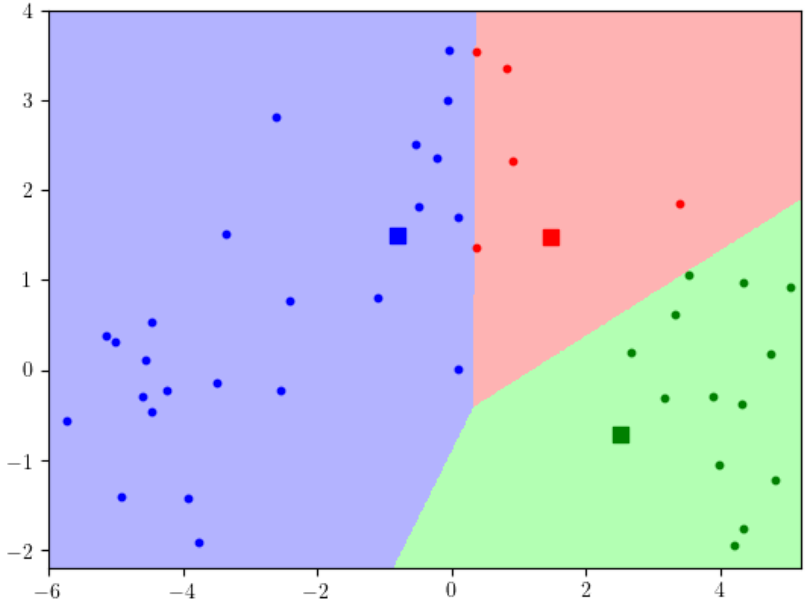

Figure: Étape d'assignation.

Un exemple non-supervisé : k-means (3)

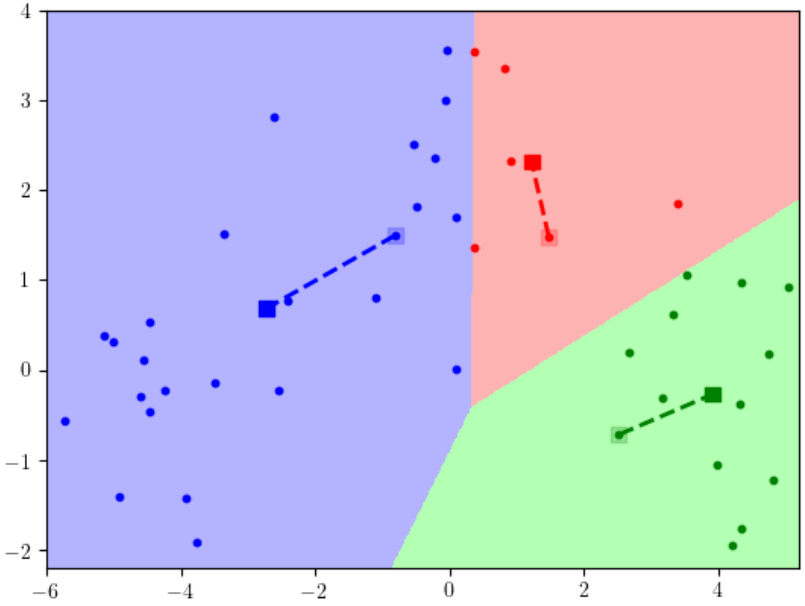

Figure: Mise à jour des centroïdes.

Un exemple non-supervisé : k-means (3)

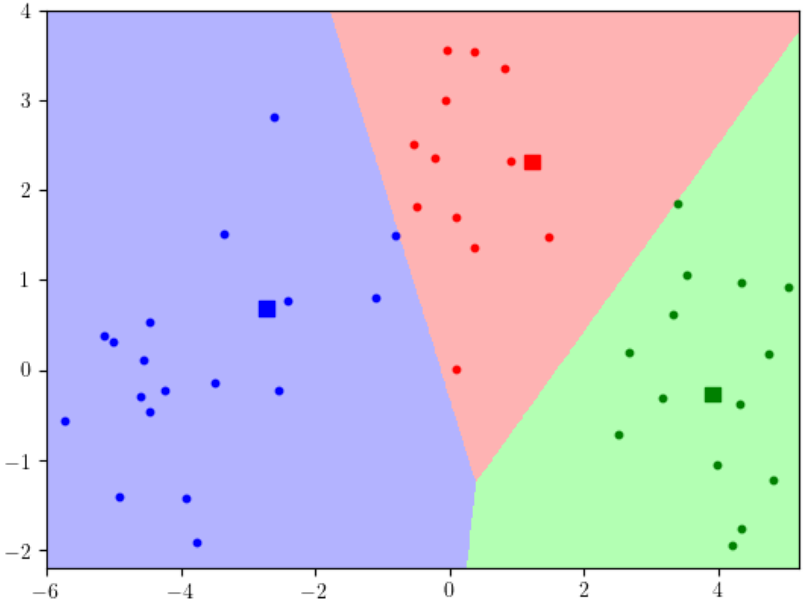

Figure: Étape d'assignation.

Un exemple non-supervisé : k-means (3)

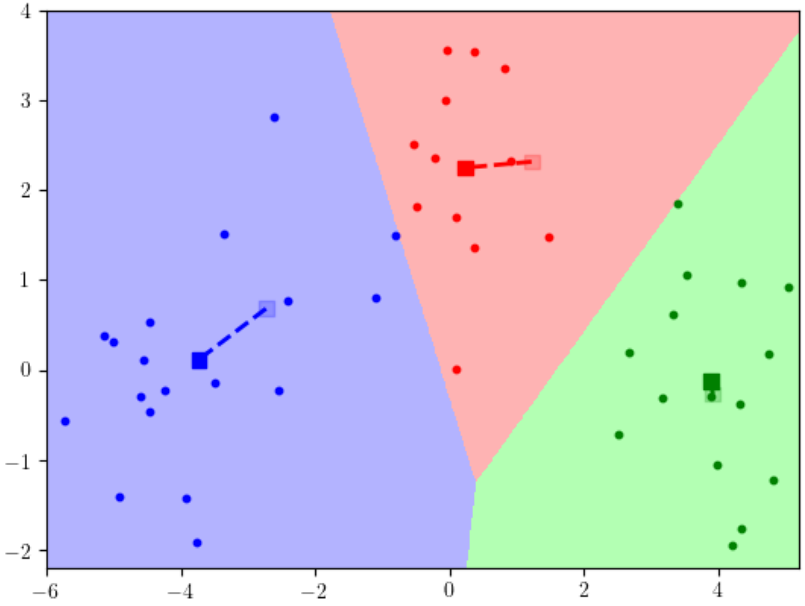

Figure: Mise à jour des centroïdes.

Un exemple non-supervisé : k-means (3)

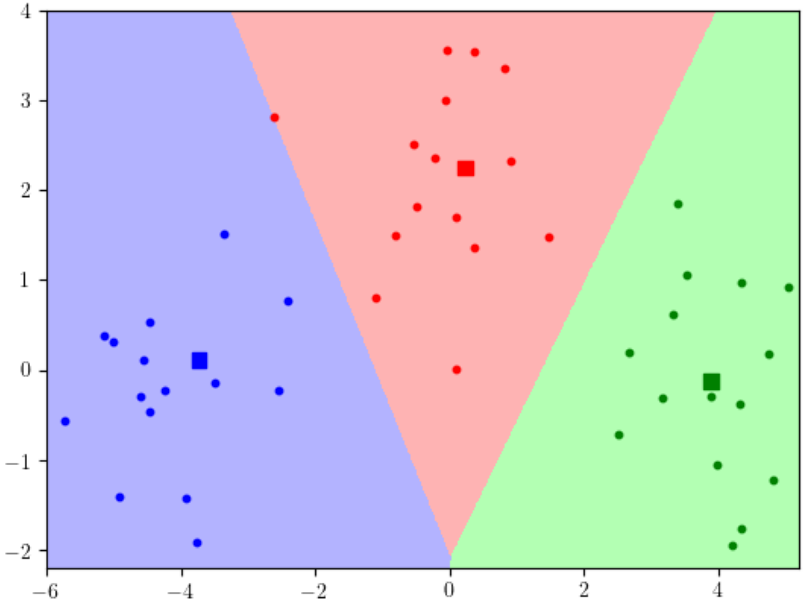

Figure: Étape d'assignation.

Un exemple non-supervisé : k-means (3)

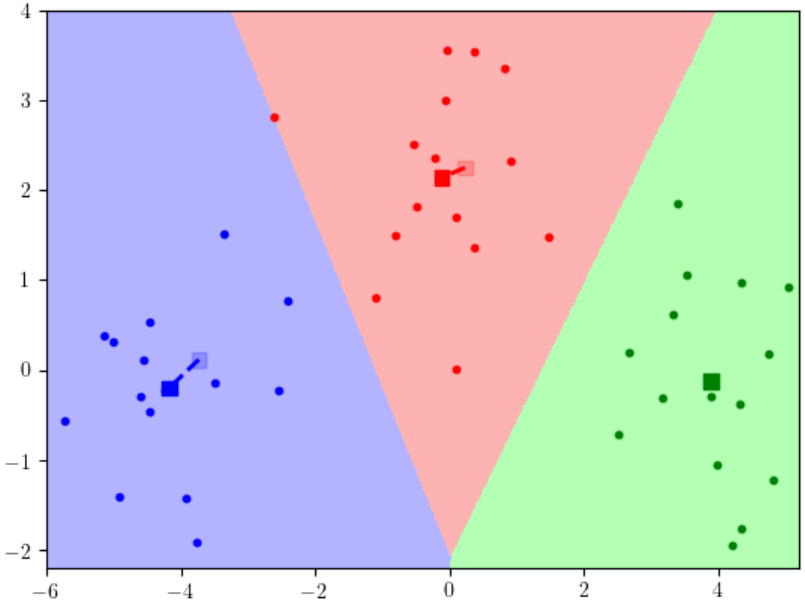

Figure: Mise à jour des centroïdes.

Un exemple non-supervisé : k-means (3)

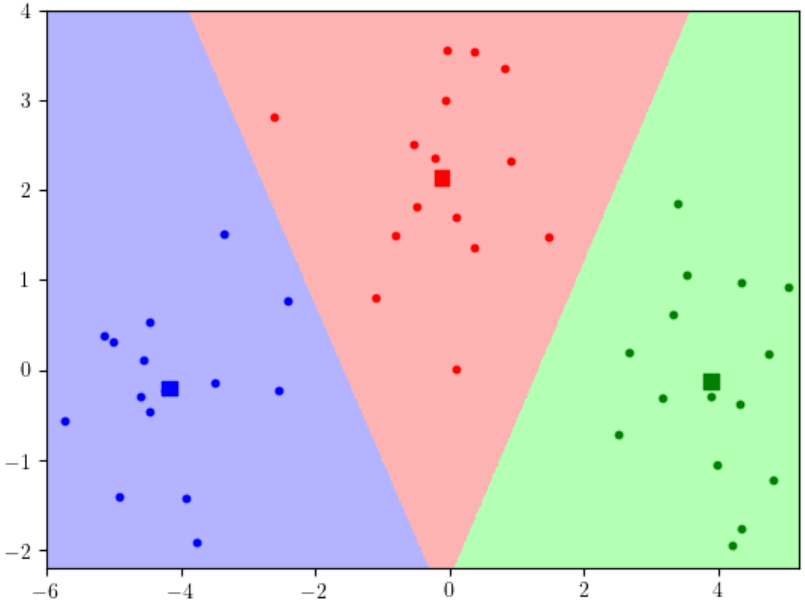

Figure: Les centroïdes ne changeront plus : on arrête.

Un exemple non-supervisé : k-means (4)

Avantages de $k - means$:

- Très simple à implémenter
- Assez rapide (moyennant quelques astuces)
- Pseudo-optimum satisfaisant si données adaptées

Inconvénients :

- Quelle métrique ?
- Aucune garantie sur la qualité du *clustering* obtenu

L'optimisation en machine learning

Méthode pour le cas général

Problème géneral en optimisation

$$\min_{\theta \in \mathbb{R}^d} f(\theta)$$

Si l'on pouvait observer le graphe de la fonction à optimiser, il serait "facile" de trouver le minimum

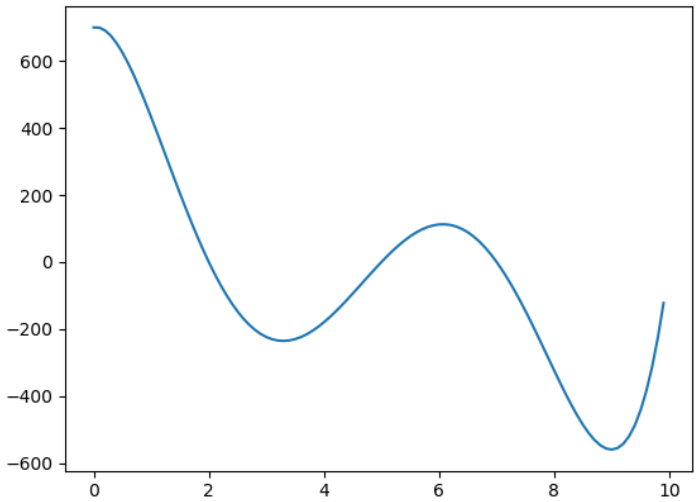

Figure: Fonction objectif.

Méthode pour le cas général

Problème géneral en optimisation

$$\min_{\theta \in \mathbb{R}^d} f(\theta)$$

Si l'on pouvait observer le graphe de la fonction à optimiser, il serait "facile" de trouver le minimum

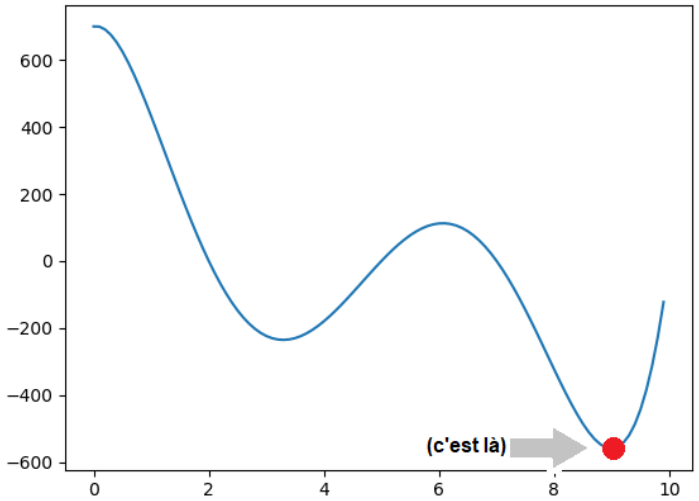

Figure: Fonction objectif.

Minimiseur : où es-tu ?

- Trouver le minimiseur du risque enmpirique n'est pas toujours possible sous forme close (ex: *k-means*)
- Problème de minimisation du risque empirique :

$$\min_{C \in \mathcal{C}} \frac{1}{n} \sum_{i=1}^{n} \ell(C(X_i), Y_i)$$

- Si $\mathcal{C}$ est l'ensemble des classifieurs linéaires et $\ell(\cdot)$ est la perte quadratique, on a une forme close
- Dans la plupart des cas, nous n'avons pas cette chance...
- C'est un problème d'optimisation : trouver l'élément qui minimise une fonction, parmi un ensemble donné

Comment ça marche ?

- Souvent, on travaille en grande dimension donc la fonction est impossible à visualiser
- La fonction objectif est trop coûteuse à évaluer (parfois même impossible !) en tout point
- Espoir : on a accès à la pente (dérivée, gradient) de la fonction au point courant
- Le gradient encode les directions dans lesquelles la fonction monte
- Méthode de la descente de gradient :
  - on part d'un point $\theta_0 \in \mathbb{R}^d$
  - à chaque étape, on met à jour en se déplaçant dans la direction du gradient

$$\theta_{t+1} = \theta_t - \gamma \nabla f(\theta_t)$$

  - γ est le pas de la descente (learning rate) : c'est un hyperparamètre qui conditionne la vitesse de notre descente

Exemple

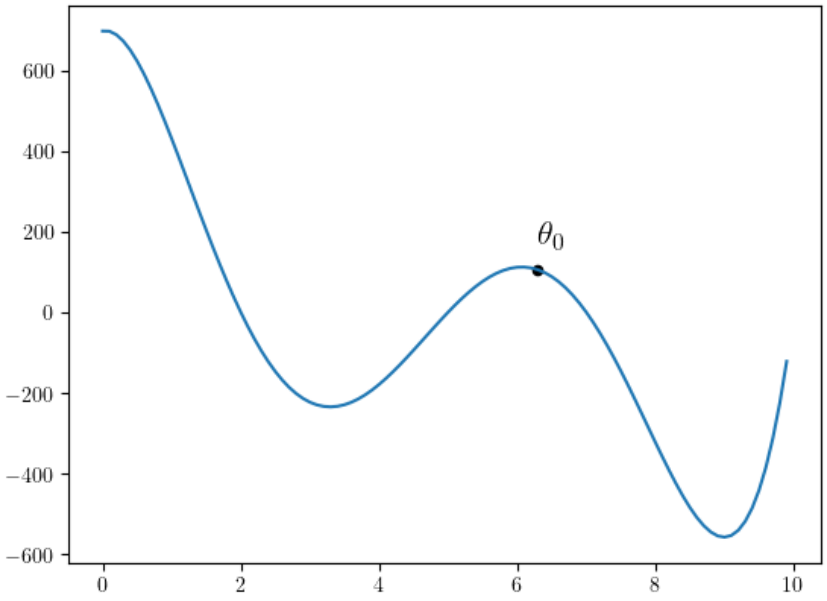

Figure: Descente de gradient sur une fonction objectif à une dimension.

Exemple

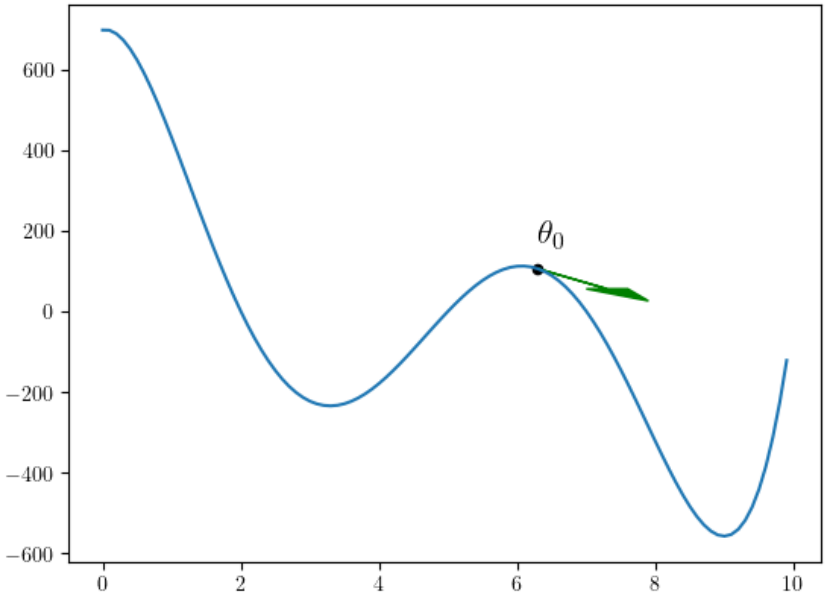

Figure: Descente de gradient sur une fonction objectif à une dimension.

Exemple

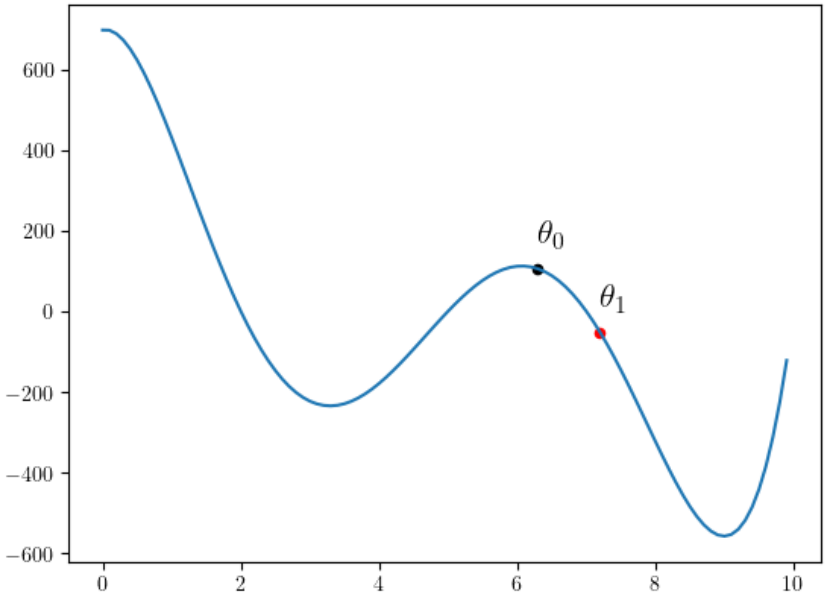

Figure: Descente de gradient sur une fonction objectif à une dimension.

Exemple

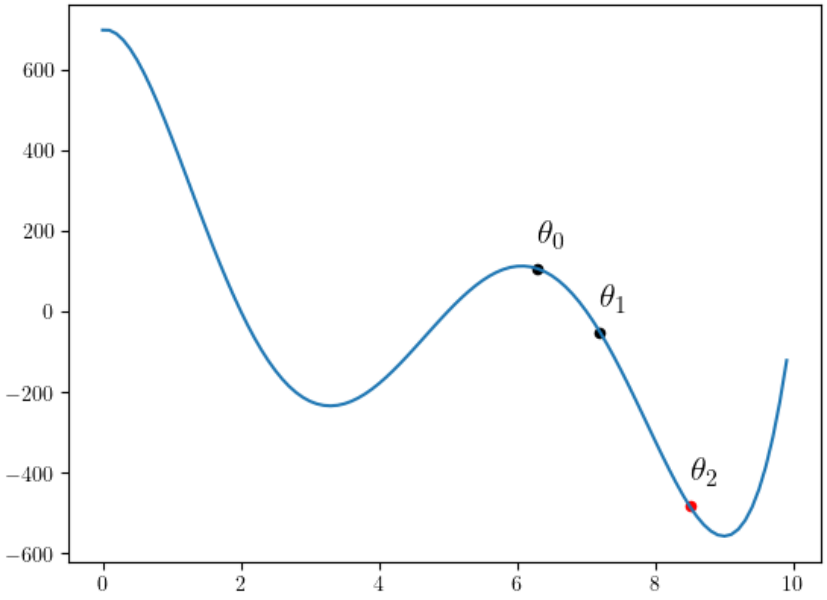

Figure: Descente de gradient sur une fonction objectif à une dimension.

Exemple

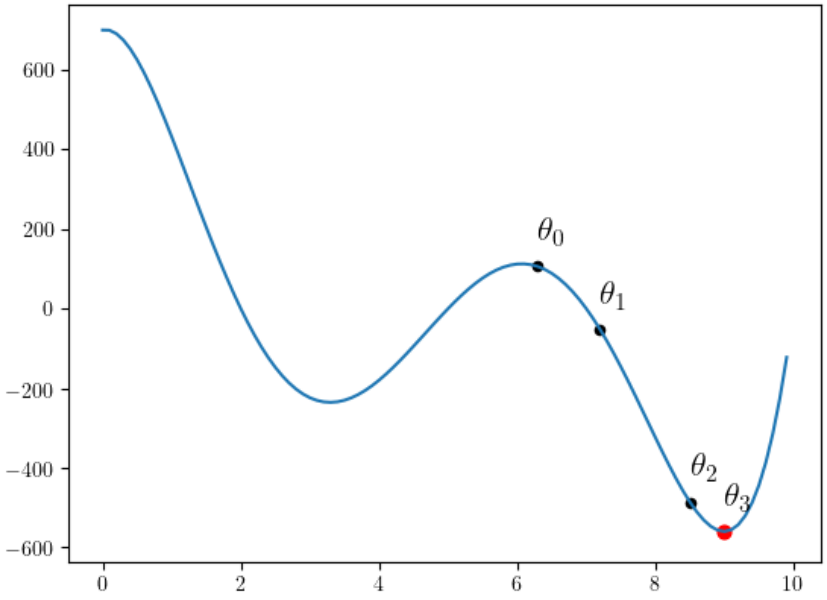

Figure: Descente de gradient sur une fonction objectif à une dimension.

- Avantages de la descente de gradient :
  - Simple à implémenter
  - Moins coûteuse que les méthodes d'ordre 2 ou quasi (Newton, BFGS)
  - Convergence rapide au début
- Inconvénients :
  - Lent à converger lorsque proche du minimum
  - Convergence dans une zone "plate" (minimum local)
- Dans certains cas, minimum local = minimum global : fonctions convexes
- On essaie souvent de trouver des fonctions de pertes convexes, ainsi le risque empirique est convexe !

Différentes fonctions de pertes

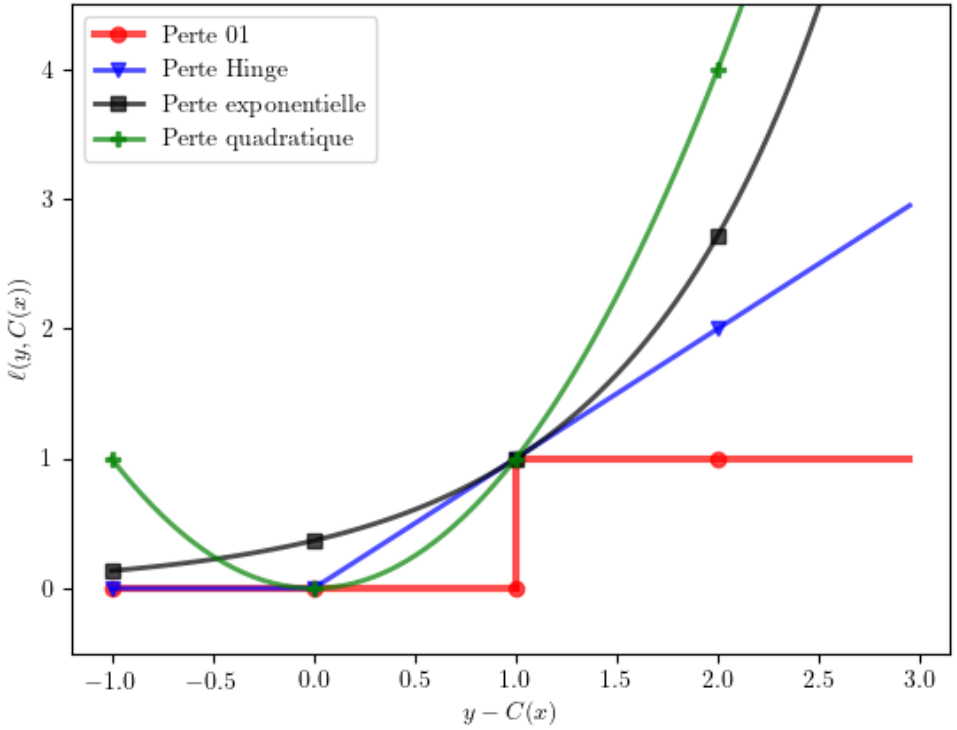

Figure: Fonctions de pertes usuelles.

Un gradient prohibitif

- Rappel : le risque empirique est une somme de n termes
- Contexte du Machine Learning : n peut être énorme (millions, milliards)
- Le gradient "complet" du risque empirique peut être trop coûteux à calculer !
- Idée : gradient **stochastique**
- Même principe que la descente de gradient mais on estime le gradient sur une petite fraction des observations, tirées au hasard (mini-batch)
- Résultats de convergences similaires à moindre coût